

WEEK 02

데이터의 종류와 수집 설계

정형·비정형 데이터, 설문·공공데이터·웹 수집

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

도입 질문

우리 학과 학생들의
통학 시간은 얼마나 되는가?

이 질문에 답하기 위한
첫 단계는?

도입

학습 목표

1 구조

표의 문법 이해
한 행이 무엇인지부터 결정

2 설계

데이터를 찾기 전에 **질문부터 확정**
순서가 뒤집히면 결과에 끼워 맞춘 해석

3 합정

수집된 데이터보다 **빠진 데이터**가 더
중요한 경우 다수

PART I · 60분

데이터와 측정의 한계

측정하지 않은 대상은 분석에 등장 불가

데이터의 세 가지 형태

정형 (Structured)

행과 열이 정해진 표
엑셀, CSV, 데이터베이스

바로 계산 가능

반정형 (Semi-structured)

구조는 있으나 표 형태는 아님
JSON, XML, 로그 파일

표로 펼친 뒤 계산 가능

비정형 (Unstructured)

텍스트, 이미지, 음성, 영상
리뷰 글, 사진, 통화 녹음

숫자로 변환 후 계산 가능

현실의 데이터 : 대부분 비정형

분석 기법 : 대부분 정형 데이터 전제

→ "표로 만드는 일"이 분석의 절반

표의 문법

표의 문법 — 행과 열

행 = 관측 하나



학생ID	학과	학년	통학시간(분)
S001	디자인	2	35
S002	경영	1	72
S003	디자인	3	18

열 = 변수 하나



관측 단위 (unit of observation) : «학생 한 명»

관측 단위 = 수집 설계에서 가장 먼저 정할 항목

학생 · 수업 · 학기 중 무엇이 한 줄인가 → 어긋나면 이후 분석 전체 흔들림

평균을 낼 수 있는 값, 없는 값

변수의 네 가지 척도

«학과의 평균» 계산은 가능하나 의미 없음

명목 Nominal	순서 Ordinal	구간 Interval	비율 Ratio
학과, 성별, 지역	학년, 만족도 1~5	온도(°C), 연도	통학시간, 매출
같다/다르다	순서 있음	간격 일정	절대 0 존재
최빈값	중앙값	평균 가능	모든 연산
평균 금지	평균 주의	0이 '없음'은 아님	배수 비교 가능

가능한 연산 증가

AI는 척도를 따지지 않고 계산 → 척도 판단은 사람의 몫

기계가 읽을 수 있는 표

정리 전

학과	2024	2025	2026
디자인	41	45	52
경영	88	83	80

연도가 «열 이름» 으로 들어간 구조

그래프마다 코드 수정 필요

2027년 자료 추가 시 열 구조 변경

정리 후 (tidy)

학과	연도	인원
디자인	2024	41
디자인	2025	45
경영	2024	88
경영	2025	83

한 행 = 한 관측, 한 열 = 한 변수

행만 늘어나고 구조는 그대로

대부분의 분석 도구가 요구하는 형태

정제의 목표 : «기계가 읽을 수 있는 표»

PART II · 30분

수집 설계

좋은 질문 → 좋은 데이터 → 좋은 분석

수집 설계의 올바른 순서

수집 설계

데이터를 찾기 전에 질문부터 확정



질문 없이 모은 데이터 → 숫자를 본 뒤 이야기를 끼워 맞추기 쉬움

조작적 정의 — 말을 숫자로 바꾸기

"통학시간이 길다" 그대로는 분석 불가 → 측정 방법부터 결정

말	조작적 정의 (예시)	이 정의가 빠뜨리는 것
통학시간	집 문을 나서서 강의실 도착까지의 분	환승 대기, 도보 구간
인기 있는 강의	수강신청 마감까지 걸린 초	재수강, 필수과목 여부
위험한 교차로	연간 인명사고 건수	통행량 차이

완벽한 정의는 없음

분석 전에 정의를 문서로 남기고, 놓치는 부분도 함께 명시

데이터 출처

설문

원하는 변수를 직접 설계 가능

질문 문구에 따라 응답 변화

유도질문·척도 설계의 영향 큼

공공데이터

data.go.kr · KOSIS

큰 규모, 높은 신뢰도

내 질문에 딱 맞는 데이터는 드물

웹 수집

공개되지 않은 데이터 확보 가능

이용약관·저작권·개인정보


수집 기술보다 적법성 판단이 먼저

이번 학기 실습 데이터 : 공공데이터


- 정제가 필요한 현실 그대로의 상태
- 행정·정책에 실제로 쓰이는 데이터
- 출처 확인이 가능한 **실재하는 데이터**

누구에게 물었는가

무작위 추출 표본평균 49.6



자발적 응답만 수집 표본평균 59.7




모집단 평균은 둘 다 49.7 · 표본을 300 → 3만으로 늘려도 오른쪽은 틀린 값 · 정밀해질 뿐 정확해지지 않음

생존자 편향

생존자 편향

구멍 없는 부위



돌아온 비행기의 구멍 자리를 보강해야 하는가?

구멍 없는 부위에 맞은 비행기 → «돌아오지 못한» 비행기

손에 쥔 데이터 = 살아남은 비행기의 기록뿐

이 데이터에 누가 빠져 있는가? — 분석 전 필수 질문

분석 전 필수 점검 질문

이 데이터에서 **빠진** 사람은 누구인가?

배달앱 리뷰 데이터

아주 좋았거나 아주 나빴던 사람만 작성
→ **보통이었던** 사람의 의견 누락

수업 만족도 설문

중도 포기한 학생은 응답 기회 없음
→ **가장** 불만족한 집단 누락

표본을 늘려도 해결 불가 → **치우친 결과만 더 정밀해짐**

PART III · 50분

바이트코딩 실습

코드 작성 : AI

요구 사항 결정과 오류 판별 : 학생

실습의 3단 루프

1 질문

알고 싶은 것을 한 문장으로 기록

2 명세

AI에게 정확한 용어로 요구

3 검증

결과를 원본과 대조해 확인

프로그래밍 지식 불필요

수업 목표 : 이상한 결과를 가려내는 판단력

AI가 지어내는 데이터

이렇게 요청하면

"부산 지역 대학생 통학시간
공공데이터 링크 좀 줘"

↓ AI의 응답

data.go.kr/dataset/3082...

「부산광역시 대학생
통학실태조사」 (2024)

그렇듯하지만 존재하지 않는 데이터

필수 확인 사항

- 링크 직접 열기
- 파일 실제로 내려받기
- 행 수와 열 이름 직접 확인
- 조사 기관·연도·조사 대상 확인

"AI가 알려줬다" 는 출처로 인정 불가

명세의 네 칸

[목표]

내려받은 CSV 파일의 구조를 파악한다.

[제약]

- 파일을 임의로 수정하지 말 것
- 결측치를 채우거나 행을 지우지 말 것 (이번 주는 «보기»만)

[검증 조건]

- 출력된 행 수가 원본 파일의 줄 수와 일치할 것
- 각 열의 자료형과 결측 개수를 표로 보여줄 것

[비목표]

- 그래프, 통계 분석은 하지 말 것

[제약]에 "하지 말 것"을 적는 이유

요청이 없어도 SI가 데이터를 임의로 정제하는 경향 → 다음 주 주제

오늘의 실습 — 50분

#	실습	확인할 개념
1	관심 주제 선정 · 질문 한 문장과 조작적 정의 작성	수집 설계
2	AI에게 관련 공공데이터 요청 링크를 하나씩 직접 열어 실재 여부 확인	AI 함정 #1
3	data.go.kr 에서 실제 CSV 내려받기	실물 확보
4	위 명세로 AI에게 구조 파악만 요청 행 수 · 열 이름 · 자료형 · 결측 개수	표의 문법
5	이 데이터로 내 질문에 답할 수 있는지 판단 불가능하면 부족한 변수 기록	설계 검증

5번 결론이 "답할 수 없음" 이어도 무방

실습 목적 : 분석 전에 데이터의 한계 파악

한 장 요약

개념	핵심
정형·비정형	현실은 비정형, 분석은 정형 전제 → 표로 만드는 작업이 절반
관측 단위	한 행의 단위 결정이 첫 단계 → 틀리면 이후 분석 전체 오류
척도	«학과의 평균» 계산은 가능하나 의미 없음 → 척도 판단은 사람 몫
tidy	한 행 = 한 관측, 한 열 = 한 변수
수집 설계	질문 → 조작적 정의 → 변수 → 출처 순서가 뒤집히면 결과에 끼워 맞추는 해석
편향	이 데이터에서 빠진 사람은 누구인가? 표본을 늘려도 해결 불가
AI 함정 #1	존재하지 않는 데이터셋을 그럴듯하게 생성 → 직접 열어 확인 필수

다음 주

데이터 정제

오늘 내려받은 파일을 직접 열기

빈칸 · 중복 · 깨진 글자 · "미상"

처리 방식에 따라 **결론이 달라지는 사례**