

WEEK 03

데이터 정제와 전처리

결측치·중복·오류 처리, 바이브코딩으로 데이터 다루기

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

도입 질문

두 팀이 같은 데이터로
같은 질문에 답변

결론은 정반대
조작한 쪽은 어느 팀인가?

도입

학습 목표

1 기술

빈칸 · 중복 · 깨진 글자
문자로 저장된 숫자
→ 찾아내고 바로잡기

2 판단

정제 방식에 따라 분석 결론 변화
→ 처리 기준을 스스로 결정

3 함정

요청하지 않은 정제를
AI가 알리지 않고 수행

PART I · 60분

현실 데이터의 문제 유형

분석 시간의 절반 이상이 정제 작업

정제 품질 = 결과의 신뢰도

다섯 줄에 다섯 가지 문제

현실의 데이터

지역	인구	면적	조사일
서울특별시	9,411,440	605.2	2026-01-01
서울시	9411440	605.2	2026.01.01
부산	-	770.1	2026-01-01
대구	2,374,960	미상	
ëŕ€ì,°	3,349,016	770.1	26/1/1

← 같은 도시가 두 이름 — 중복인가 다른 관측인가

← 천 단위 쉼표 → 숫자 대신 «문자» 로 인식

← 빈칸을 «-» 로 표기

← «미상» 과 빈칸 — 뜻이 같은가 다른가

← 인코딩 깨짐 (CP949 를 UTF-8 로 읽음)

작은 표 하나에 이미 문제 다섯 가지

내려받은 공공데이터의 혼한 상태 · 분석 시간의 절반 이상이 정제에 소요

숫자처럼 보이는 문자

화면에 보이는 값	실제 자료형	발생하는 문제
9,411,440	문자	합계 계산 오류 또는 엉뚱한 값
12%	문자	0.12 인지 12 인지 불분명한 채로 계산
2026.01.01	문자	날짜 대신 글자 순서로 정렬
001	숫자로 읽힐 경우	앞자리 0 이 사라져 1 로 변환 우편번호·학번에서 빈번

엑셀로 CSV 열기 주의

여는 즉시 학번 앞자리 0 삭제 · 날짜 형식 변경

→ 그대로 저장하면 원본 손상

인코딩 — 국내 공공데이터의 혼한 문제

부산 → ë¶€ì,°

서울 → ¼¿ì

파일 내용은 멀쩡한 상태

저장 방식과 다른 방식으로 읽은 결과

발생 원인

국내 공공기관 파일 : **CP949(EUC-KR)** 저장이 여전히 다수

최신 분석 도구 : 기본값 **UTF-8** 로 읽기

해결 : AI에게 "인코딩을 **cp949** 로 지정해서 읽어줘"

용어를 모르면 원인 찾기에만 30분

결측치가 생기는 이유

결측치 — 세 가지 이유

결측 여부보다 «왜 비었나» 가 중요

우연한 결측

커피에 젖은 설문지 한 장

삭제해도 대체로 안전

다른 변수에 따른 결측

고학년일수록 소득 문항 건너뛴

학년 정보로 보완 가능

값 자체가 원인인 결측

고소득자일수록 소득 미기재


삭제 시 결론 전체 왜곡

«결측치 처리해줘» 만 요청하면 AI는 세 경우를 똑같이 처리


세 번째를 두 번째처럼 다룸 → 코드는 정상 실행, 결론만 틀림

평균 대치의 결과

원래 분포 평균 40.4 · 표준편차 11.6



평균으로 채운 뒤 평균 40.3 · 표준편차 9.2



평균은 그대로, «흩어진 정도» 만 감소 · 이 데이터로 검정하면 없는 차이도 유의하게 나옴

AI가 가장 자주 선택하는 기본 처리 — 11주차 p값과 직결

정제 · 5 ★

결측 비율 조절

인터랙티브 데모

이 자리에는 직접 조작하는 3D 데모

HTML 슬라이드를 브라우저로 열어 확인

중복과 이상치 — 지울 것인가

중복처럼 보이는 행

같은 사람의 두 번 응답 → 삭제

같은 사람의 두 학기 수강 → 삭제 불가

행 전체가 같은지, 식별 열만 같은지 먼저 확인

이상치처럼 보이는 값

통학시간 **480**분

· 입력 오류?

· 실제 제주 통학?

원본 확인 전에는 삭제 금지

이상치를 찾는 방법 : 5주차 (z-점수)


오늘 다룰 내용 : 찾은 뒤의 처리 기준

PART II · 30분

정제 규칙과 판단

정제 방식은 분석자의 선택 → 선택 근거 기록 필요

같은 데이터, 다른 결론



숫자 조작 없음 · 정제 규칙 한 줄로 승자 역전

정제 방법을 기록하지 않은 분석 → 검증 불가

정제 규칙 운영 원칙

정제 규칙은 분석 전에 확정
정한 규칙은 그대로 기록

결과를 본 뒤 규칙 변경 → 원하는 답에 맞춘 분석

10~11주차 A/B 테스트에서 같은 문제 재등장

정제 로그

정제 로그

무엇을	왜	어떻게	영향받은 행
'-', '미상' → 빈칸	결측 표기가 세 가지	전부 NA 로 통일	412
인구 열 문자→숫자	십표 때문에 문자였음	십표 제거 후 정수	1,204
'서울시'→'서울특별시'	같은 지역 다른 표기	행정표준코드 기준	37
통학 480분 유지	제주 통학, 오류 아님	제거하지 않음	2

핵심은 네 번째 줄 — «지우지 않기로 한 결정» 도 기록

정제 로그 있음 → 결론이 의심받을 때 원인이 된 결정 추적 가능

정제 로그 없음 → «데이터가 그렇게 나왔다» 는 설명뿐

PART III · 50분

바이트코딩 실습

AI에게 정제를 맡길 때

수행한 **작업** 전체 보고 요구

묻지 않고 고치는 AI

이렇게 요청하면

"이 데이터 정제해줘"

↓ AI가 알리지 않고 수행하는 작업

- 결측치를 평균으로 채움
- 중복처럼 보이는 행 삭제
- 이상치를 자동으로 제거
- 자료형을 알아서 변환

보고는 «정제 완료!» 한 줄

올바른 요청

"어떤 문제가 있는지 **보고만** 해줘.
아직 아무것도 고치지 마."

↓ 그 다음

- 문제를 직접 확인
- 처리 방법을 직접 결정
- **결정한 작업만** 요청
- 처리 전후 행 수 비교

이번 주 명세

[목표]

지난주 내려받은 CSV 의 문제를 «진단만» 한다.

[제약]

- 아무것도 고치지 말 것. 채우지도, 지우지도 말 것
- 원본 파일을 덮어쓰지 말 것

[검증 조건]

- 열별로: 자료형 / 결측 개수 / 고유값 개수 를 표로
- 결측이 있는 열은 «어떤 값으로 표시되어 있는지» 실제 예시를 보여줄 것
(빈칸인지, '-' 인지, '미상' 인지)
- 완전히 동일한 행이 몇 개인지
- 처리 전 행 수를 맨 위에 출력할 것

[비목표]

- 정제, 그래프, 통계 분석

가장 중요한 줄 : [제약]의 첫 줄

진단과 처리를 나누기 = 데이터 분석의 기본기

오늘의 실습 — 50분

#	실습	확인할 개념
1	위 명세로 진단만 요청 처리 전후 행 수로 SI의 임의 수정 여부 확인	SI 함정 #2
2	결측이 있는 열 하나 선택 비어 있는 이유 가 세 유형 중 어디인지 판단	결측의 이유
3	같은 열을 ① 행 삭제 , ② 평균 대체 로 각각 처리 평균과 표준편차 비교	정제에 따른 수치 변화
4	결정 내용을 정제 로그 에 기록 지우지 않기로 한 결정도 포함	재현 가능성
5	글자가 깨진 파일을 직접 만든 뒤 <code>cp949</code> 로 복원 (확장)	인코딩

가장 중요한 실습 : 3번 — 두 방법의 수치 차이 직접 확인

한 장 요약

개념	핵심
자료형	윺표·%·앞자리 0 → 숫자처럼 보여도 문자 엑셀로 CSV 열기 주의
인코딩	글자 깨짐 원인 : 저장·읽기 방식 불일치 → cp949 지정
결측	«비었다»보다 «왜 비었나»가 중요 세 유형을 같게 처리하면 결론 왜곡
평균 대치	평균은 유지, 표준편차만 감소 → 없는 차이가 유의하게 보임
중복·이상치	삭제 전 원본 확인 — 480분은 입력 오류일 수도, 제주 통학일 수도
정제 규칙	규칙 한 줄로 승자 변경 결과를 본 뒤 규칙 변경 = 원하는 답에 맞춘 분석
정제 로그	기록 없는 분석은 검증 불가 지우지 않기로 한 결정도 기록
AI 함정 #2	요청 없이 채우고 지우는 AI → 진단과 처리를 나눠 요청

다음 주

기술통계 기초

평균·중앙값·분산·표준편차

오늘 본 «표준편차 감소»의 정확한 의미