

WEEK 04

기술통계 기초

평균·중앙값·분산·표준편차, 분포의 이해

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

도입 질문

4,900만원

두 회사의 평균 연봉 동일

A사: 20명 중 17명이 평균 이하

B사: 거의 전원이 평균 근처

평균은 같은데 두 회사 사정이 다른 이유는?

도입

학습 목표

1 기술

평균·중앙값·분산·표준편차가 각각 무엇을 재는지 구분

2 판단

상황에 맞는 **대푯값** 선택과 근거 제시

3 함정


«요약해줘» 요청 시 AI가 **평균만** 보고하는 문제

숫자 몇 개로 수천 개를 요약

기술통계(descriptive statistics) = 요약
요약하면 반드시 빠지는 정보 발생
무엇이 빠지는지 확인하는 것이 오늘의 핵심

도입 질문의 답

평균 연봉 4,900만원인 회사



점선 상자 안 — 직원 19명만 확대



채용공고의 «평균 연봉 4,900만원» — 사실이지만 그 근처 연봉을 받는 사람은 0명

평균 : 모든 값을 더함 → 아주 큰 값 하나에 끌려감 · 중앙값 : «줄을 세웠을 때 한가운데 사람» → 영향 거의 없음

평균의 장점과 한계

평균의 장점

모든 값을 빠짐없이 반영
전체 합을 개수로 나눈 값 → 총량과 직결
계산이 쉬움
이후 배울 통계 대부분이 평균에서 출발

평균의 한계

모든 값을 반영 → 극단값 하나에 크게 이동
평균의 위치 = 가운데보다 무게중심
평균 위치에 실제 사람이 있는지는 알 수 없음

평균 = 시소의 받침점

끝에 앉은 한 사람이 무거우면 받침점이 그쪽으로 이동
나머지 사람이 몇 명이든 마찬가지

중앙값과 최빈값

대푯값	정의	극단값의 영향	적합한 상황
평균 mean	전체 합 ÷ 개수	크게 받음	좌우 대칭, 극단값 없음
중앙값 median	크기순 정렬 시 한가운데 값	거의 없음	연봉·집값·대기시간처럼 한쪽으로 늘어진 분포
최빈값 mode	가장 자주 나온 값	거의 없음	색깔·학과처럼 숫자가 아닌 항목

중앙값 : **순서만 반영**
맨 오른쪽 연봉이 3억이든 300억이든 한가운데 사람은 그대로

대 쫓 값 · 4 ★

치우침·이상치에 따른 평균과 중앙값 변화


인터랙티브 데모

이 자리에는 직접 조작하는 3D 데모

HTML 슬라이드를 브라우저로 열어 확인

평균이 같은 서로 다른 데이터

세 반의 기말고사 점수 — 평균은 셋 다 50점



평균은 모두 50점 — 세 반에 같은 보충수업이 맞는가?

3주차 «평균 유지, 표준편차 감소»의 의미 · 가운데가 같아도 흩어진 정도가 다르면 다른 데이터

3주차 «표준편차 감소»의 의미

3주차에서 확인한 사실

«평균으로 빈칸을 채우면 평균은 그대로인데 **표준편차만 줄어든다**»

당시의 인상

숫자 하나가 조금 작아진 정도
평균이 그대로라 문제없어 보임

실제 의미

빈칸을 모두 **평균값**으로 채움
= 편차가 **정확히 0**인 가짜 값을 대량으로 추가
→ **C반이 A반처럼 보임**

결과 : 데이터가 실제보다 **고르게** 보임

11주차 : **없는 차이를 «유의하다»**고 잘못 판정하는 원인

흠어진 정도의 측정

다섯 명의 점수 60 · 70 · 75 · 80 · 90




① 각 값에서 평균 빼기 = «편차»

그대로 더하면 $(-15) + (-5) + 0 + 5 + 15 = 0 \rightarrow$ 왼쪽과 오른쪽이 상쇄

부호를 그대로 두면 «흠어진 정도» 측정 불가 $\rightarrow$ 다음 단계 필요

② 제곱 — 편차를 한 번으로 하는 정사각형

$$225 + 25 + 0 + 25 + 225 = 500$$



③ 평균 = 분산

$$500 \div 5 = 100 \text{ 점}^2$$

왜 제곱하는가

- 부호 제거

- 멀리 떨어진 값일수록 크게 반영

왜 다시 제곱근을 씌우는가

- 분산의 단위 «점²» $\rightarrow$ 뜻을 말하기 어려움

- 제곱근 $\rightarrow$ 단위가 «점» 으로 복귀

- 평균과 나란히 해석 가능

표준편차 10점 = «다들 평균 75점에서 대체로 10점쯤 떨어져 있다»

분산 = 편차²의 평균 · 표준편차 = $\sqrt{\text{분산}}$ · 뜻은 «평균에서 얼마나 떨어져 있다» 하나

표준편차의 해석

평균 75점, 표준편차 10점

→ «다들 75점에서 대체로 10점쯤 떨어져 있다»

평균 75점, 표준편차 2점

→ «거의 다 73~77점에 몰려 있다»

단위 차이

표준편차 : 원래 단위(점, 원, 분) 그대로

→ 평균과 나란히 놓고 해석 가능

분산 : 단위가 점² → 계산 중간 단계로만 사용


평균과 짝으로 보고

평균만 적은 보고서 = 미완성

평균 옆에 흘어진 정도 필수

평균 75점 (표준편차 10점, n=32)

분포의 모양 네 가지



이봉 분포와 평균의 위치

봉우리가 두 개인 경우

40점대 무리와 80점대 무리의 혼합

평균 63점

63점 근처 인원이 가장 적음 → 평균이 아무도 없는 자리를 가리킴

봉우리 두 개 → 대개 서로 다른 두 집단이 섞인 경우
평균으로 요약하기 전에 집단 분리 필요

현실의 예

- 수강생 점수 — 재수강생과 신규 수강생
- 앱 체류시간 — 무료 사용자와 유료 사용자
- 통학시간 — 자취생과 통학생
- 매출 — 평일과 주말


섞인 두 집단을 나눌 기준 변수 탐색 → 7주차 상관·교차분석으로 연결

앤스컴 4중주


I. 실제 직선 관계



II. 곡선 관계에 직선 적용



III. 이상치 하나로 기울기 왜곡



IV. x 값이 하나 빼고 전부 동일



x 평균 9.0 · y 평균 7.5 · x 분산 11.0 · y 분산 4.1 · 상관계수 0.82 · 회귀직선 $y = 3.00 + 0.50x$

네 데이터 모두 위 여섯 숫자 동일 — 소수점 셋째 자리에서야 차이

요약 숫자가 같아도 다른 데이터 → 그려 보기 전에는 판단 불가

PART II · 30분

보고할 숫자의 선택

평균과 중앙값 중 무엇을 쓸지
계산보다 전달할 내용에 따라 결정

상황별 대푯값 선택


상황	보고할 값	이유
신입 연봉 수준 파악	중앙값	임원 몇 명이 평균을 끌어올림
인건비 예산 편성	평균	총액 필요 · $\text{평균} \times \text{인원} = \text{총액}$
일반적인 배달 소요 시간	중앙값	2시간짜리 사고 한 건에도 평균 왜곡
두 반의 성적 비교	평균 + 표준편차	평균이 같아도 흩어진 정도가 다를 수 있음
설문 만족도 요약	분포 전체	평균 3.0점 ≠ «보통»

기본 규칙 : 평균과 중앙값을 함께 계산

두 값의 차이가 크면 그 차이도 보고


평균이 판단을 흐리는 사례

① 평균 수심 1m 인 강



평균은 사실, 그래도 익사 위험

② 만족도 평균 3.0점



칭찬과 분노가 반반 → 평균에서는 사라짐

③ 표본이 작을 때



별점 4.7(3명) 과 4.7(3,000명) 은
의미가 다른 숫자

한 사람의 응답으로 평균이 크게 이동

평균은 요약일 뿐 · 데이터 설명으로는 부족

요약을 믿기 전 확인할 세 가지 — 흩어진 정도 · 분포 모양 · 표본 크기

평균을 볼 때 확인할 세 가지

1 흩어진 정도

표준편차 없는 평균 = 절반의 정보

2 분포 모양

봉우리 개수 · 한쪽으로 늘어진 정도

3 응답자 수

4.7점(3명)과 4.7점(3,000명)은 다른 숫자

보고서를 읽을 때와 쓸 때 모두 적용

셋 중 하나라도 빠진 평균 → 해석 오류

핵심 원칙

같은 요약 수치 ≠ 같은 데이터
시각화 전에는 판단 불가

앤스컴의 네 데이터 : 평균·분산·상관계수·회귀직선 모두 동일
실제로는 전혀 다른 데이터 → 그림 한 장이면 바로 구분

실습 검증 조건에 «그러서 보여줄 것»이 항상 포함되는 이유

PART III · 50분

바이트코딩 실습

AI 요약이 **평균 하나로 끝나지 않게** 명세 작성

평균만 보고하는 AI 요약

이렇게 요청하면

"이 데이터 요약해줘"

↓ 어떤 데이터든 비슷한 응답

- 평균 63.4
- 최댓값 92, 최솟값 31
- 행 480개, 열 7개
- "전반적으로 중간 수준입니다"

치우침·이봉 분포·이상치가 있어도
같은 형태의 답

올바른 요청

"평균과 중앙값을 같이 보고하고,
두 값이 다르면 왜 다른지 설명해줘.
그리고 히스토그램을 그려줘."

↓ 드러나는 정보

- 꼬리 방향
- 봉우리 개수
- 이상치 존재 여부
- 평균의 대푯값 적합성

이번 주 명세

[목표]

내 데이터의 숫자 열 하나를 «기술통계로 요약» 하고,
평균 하나로 요약해도 되는 열인지 판정한다.

[제약]

- 결측치를 평균으로 채우지 말 것. 땀 행 수를 밝힐 것
- 이상치를 임의로 지우지 말 것
- 그래프 색은 지정하지 말고 기본값으로 둘 것

[검증 조건]

- 평균과 중앙값을 «함께» 보고할 것. 둘의 차이도 같이 적을 것
- 표준편차와 함께 n (사용한 행 수) 을 반드시 적을 것
- 분포를 «반드시 그릴 것» - 히스토그램, 구간 20개 이상
- 최솟값·최댓값과 그 값을 가진 행을 같이 보여줄 것
- 마지막 줄에 한 문장으로 답할 것:
«이 열은 평균으로 요약해도 되는가 / 안 되는가 · 그 이유»

[비목표]

- 상관, 예측, 통계적 검정
- 예쁜 그래프 꾸미기

핵심 : [검증 조건] 셋째 줄

그래프를 요청하지 않으면 시가 그리지 않음 → 분포 문제 발견 불가

오늘의 실습 — 50분

#	실습	확인할 개념
1	"이 데이터 요약해줘" 한 줄만 입력 → 결과 저장	AI 함정 #3
2	위 명세로 다시 요청 → 1번 결과와 비교 해 늘어난 내용 기록	질문에 따른 답변 변화
3	평균과 중앙값 차이가 가장 큰 열 찾기 → 차이의 원인 을 그림으로 설명	치우침
4	두 집단으로 나눌 기준 열 선택 → 집단별 평균·표준편차 계산	이봉 분포
5	3주차 «평균 대치»로 만든 열이 있으면 원본과 표준편차 비교 (확장)	3주차 내용 연결

1번과 2번 결과 **나란히 비교** · 제출물 없음, 수업 안에서 완료

한 장 요약

개념	핵심
평균	가운데보다 무게중심 → 극단값 하나에도 크게 이동
중앙값	순서만 반영 → 극단값에 강함 연봉·집값·대기시간에 적합
분산	편차 제곱의 평균 · 단위가 점 ² → 직접 해석 곤란
표준편차	√분산 → «평균에서 대체로 떨어진 거리», 원래 단위
3주차 연결	평균 대치 = 편차 0인 가짜 값 추가 → 데이터가 실제로보다 고르게 보임
분포의 모양	대칭일 때만 평균~중앙값 · 치우치면 꼬리 쪽으로 평균 이동
이봉	봉우리 두 개 → 두 집단이 섞였을 가능성 · 요약 전에 분리
앤스کم	요약 수치 여섯 개가 같아도 전혀 다른 데이터 → 그러 보기 전 판단 불가
보고 규칙	평균 옆에 표준편차와 n · 평균과 중앙값 차이도 함께 보고
시 함정 #3	«요약해줘» → 평균만 보고 · 명세에 중앙값과 분포 그래프 포함

다음 주

z-점수와 표준화

국어 80점과 수학 80점, 더 잘한 과목은?

오늘 배운 **평균과 표준편차**로

기준이 다른 점수를 같은 잣대로 비교