WEEK 10

A/B 테스트 설계하기

가설 · 실험군과 대조군 · 무작위 배정
비전공자를 위한 바이브코딩 실습

데이터리터러시의이해 SF1101084 · AI융합교육원
조성호 · 2026학년도 2학기



도입 질문

새 버튼 도입 후
클릭 2배

버튼 효과로 볼 수 있는가?



도입

학습 목표

① 설계

가설 · 실험군/대조군 · **무작위 배정**의 역할 설명

A/B 구성요소 6종으로 설계서 작성

② 판단

전후 비교·자원자 비교의 **한계** 판별

설계 점검표로 실험 합격 여부 판정

③ 바이브코딩

AI 에이전트로 **A/B 페이지** 제작

새로고침 · 배정 비율 · 로그로 AI 결과 검증

오늘의 결과물 · 학식 쿠폰 A/B 페이지 + 일상 속 A/B 설계서 · 코드 작성은 AI · 평가 대상은 명세와 검증

도입

오늘 다룰 내용

시간	블록	내용
10:00–10:10	도입 질문	새 버튼과 클릭 2배
10:10–11:10	**Part I 개념**	전후 비교 한계 · 가설 · 무작위 배정 · 6요소 · 표본 크기
11:10–11:20	휴식	
11:20–11:50	**Part II 판단**	설계 점검표 · 사례 판정 · 지표 고르기 · AI 함정 #8
11:50–12:40	**Part III 실습**	명세 → AI 생성 → 관찰 → 수정
12:40–13:00	정리	한 장 요약 · 과제 브리핑

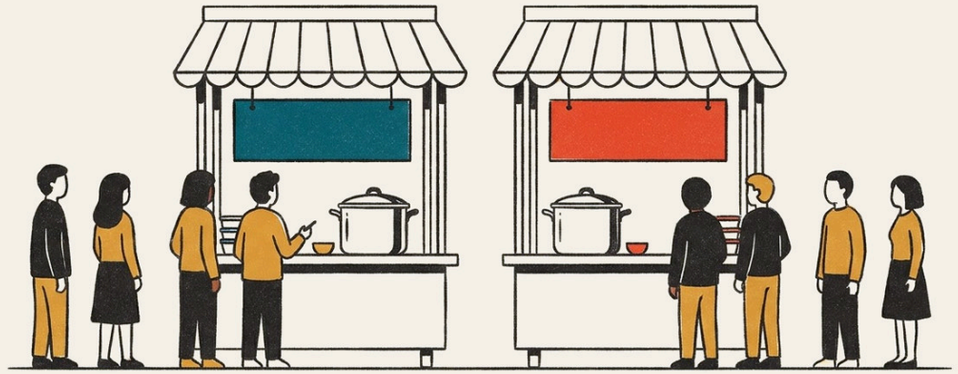
이어지는 흐름 · 9주 «상관≠인과» → 10주 인과 확인 실험 설계 → 11주 실험 결과 해석

PART I · 60분

비교를 공정하게

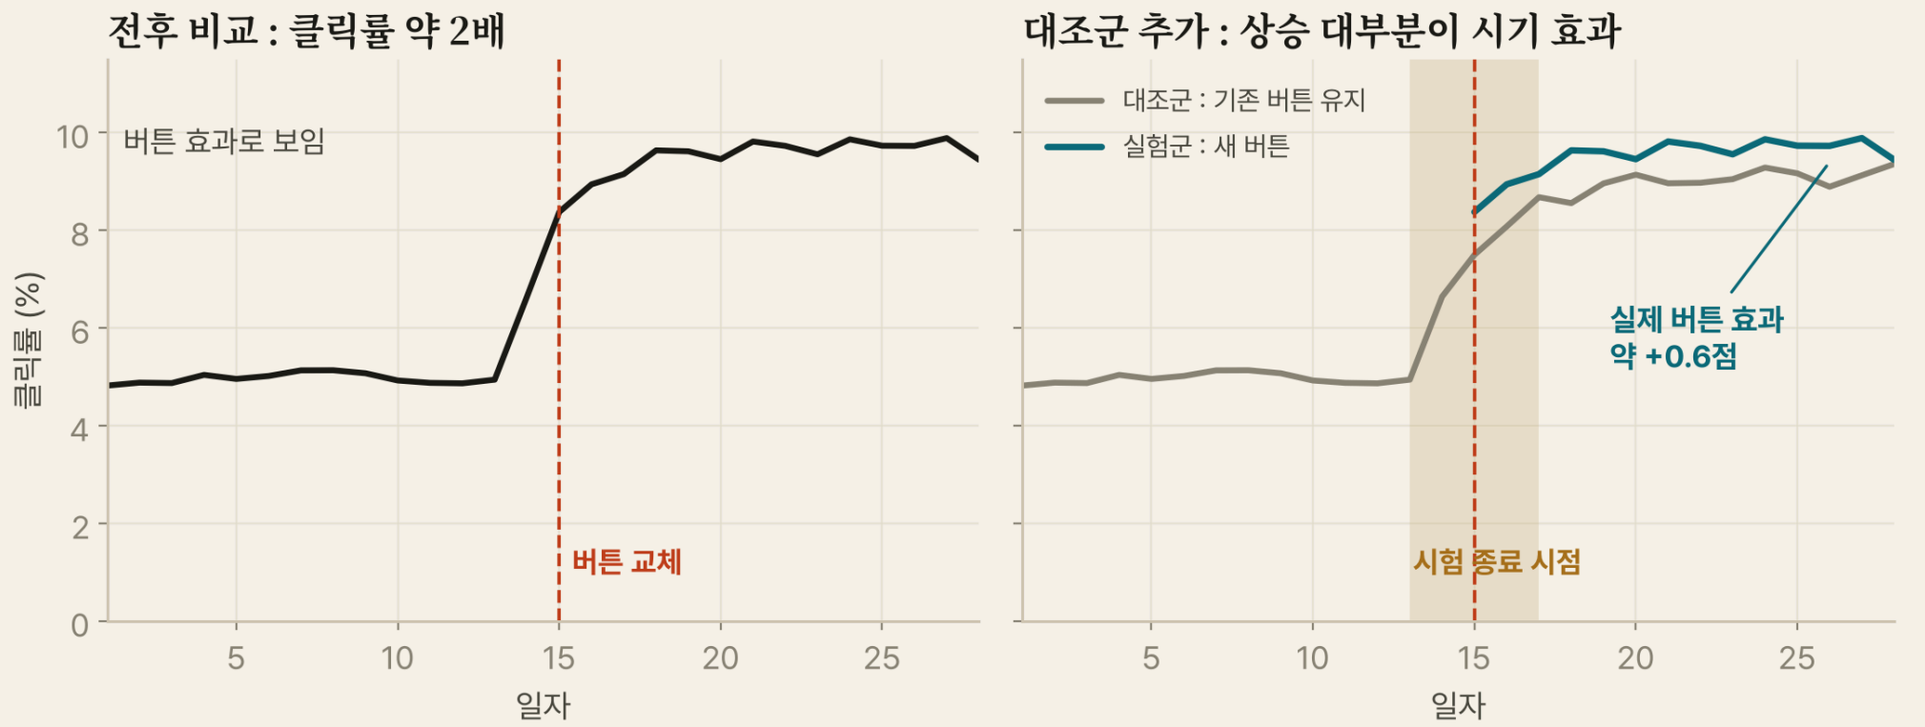
전후 비교로 알 수 없는 것

대조군과 무작위 배정의 역할



개념 · 1 ★

전후 비교의 한계

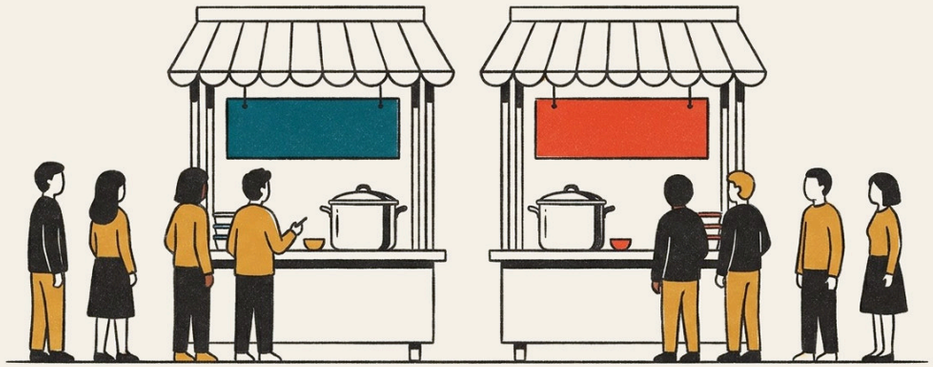


교육용 합성 데이터

도입 질문 답 · 판단 불가 · 같은 시기의 시험 종료 · 방학 · 축제 · 광고가 함께 작용 → 비교 대상 필요

개념 · 2

A/B 테스트 : 같은 시기 · 같은 조건 · 한 가지만 다르게



비유

쌍둥이 분식집 : 맛·위치·날씨·손님 동일 · 메뉴판 색만 상이

매출 차이의 원인 후보 = 메뉴판 하나

- A = 기존안 · B = 변경안
- 같은 기간에 동시 운영 → 시기 효과 제거
- 사람을 난수로 나눔 → 사람 차이 쏠림 방지 (완전 일치는 아님)
- 남는 차이 = 변경 효과 + 우연

남은 문제 · 차이 중 우연의 몫 구분 → 11주 주제

개념 · 3

실험 용어 4개

처치
Treatment

실험에서 일부러 바꾼 것 하나

예 버튼 문구를 «쿠폰 받기» → «오늘 점심 500원 아끼기»로 변경

실험군
Treatment group

처치를 받은 집단 (B안)

예 새 문구 화면을 본 학생들

대조군
Control group

처치를 받지 않은 비교 기준 집단 (A안)

왜 없으면 «어차피 일어났을 변화»와 효과 구분 불가

지표
Metric

성공 여부를 재는 숫자

예 클릭률 = 클릭한 학생 수 / 화면을 본 학생 수

어디서 앱 로그 · 설문 · 매출 기록

개념 · 4

일상 속 A/B 예시

상황	A (기존)	B (변경)	지표	배정 단위
학습법	평소대로 복습	공부 후 퀴즈 10문제	2주 뒤 시험 점수	학생
알림 문구	«강의자료 등록»	«오늘 자료 5분 요약»	24시간 내 열람률	수강생
진열 위치	음료 안쪽 냉장고	음료 계산대 옆	매장당 음료 판매량	매장·요일
가격 표시	«4,500원»	«4,500원 · 쿠폰 시 3,900원»	주문 전환율	방문자
모집 포스터	활동 소개 중심	선배 후기 중심	QR 스캔 후 신청률	건물별 게시판
유튜브 썸네일	얼굴 + 제목	결과 장면 + 제목	노출 대비 클릭률	시청자

공통 구조 · 바꾼 것 하나 · 측정 숫자 하나 · 누구에게 어느 안을 보여 줄지 사전 결정

개념 · 5

왜 실무에서 실험하는가

+12%

Bing 광고 제목 (2012)

제목 줄 길이 변경 하나로 매출 12% 증가

미국 내 연 1억 달러 이상 규모

+40.6%

오바마 캠프 가입 화면 (2008)

사진·버튼 조합 변경 · 가입률 8.26% → 11.6%

(원문 표기 +40.6%)

추가 기부 약 6천만 달러는 캠프 측 추정

10~20%

Google·Bing 실험 성공률

긍정 결과를 낸 실험 비율

대부분의 아이디어 효과 없음 또는 역효과

> 전문가 직감도 자주 빗나감 → **의견**을 **증거**로 바꾸는 절차가 A/B 테스트

가설 · 1

가설 : 데이터 수집 전에 쓰는 두 문장

귀무가설 H_0

«차이 없음» · 기본 입장

버튼 A와 B의 클릭률 동일

대립가설 H_1

«차이 있음» · 확인하려는 주장

버튼 B의 클릭률이 A와 상이

① 가설 선언 — 데이터 수집 전

② 데이터 수집 — 기간·표본 고정

③ 판단 — H_0로 설명 가능한가?

비유

재판의 무죄 추정 : 일단 «차이 없음»으로 출발 · 증거가 충분할 때만 뒤집기

가설 · 2

가설 문장 고치기

측정 불가

«새 디자인이 더 좋을 것»

«쿠폰 문구를 바꾸면 효과가 있을 것»

«퀴즈 공부법이 도움이 될 것»

측정 가능

«B 화면의 가입 완료율이 A와 다를 것»

«B 문구의 14일 클릭률이 A와 다를 것 (찾을 효과 +2점)»

«퀴즈 집단의 2주 뒤 시험 평균이 대조군과 다를 것»

빈칸 공식 **[대상]**에게 **[처치]**를 적용하면 **[기간]** 동안 **[지표]**가 **[기준]**과 비교해 **[방향·크기]**로 변화

배정 · 1 ★

집단을 나누는 세 가지 방법

자원자 모집

원하는 사람만 처치

실험군 대조군



81% 16%

처치 전부터 집단 차이 큼

사후 비교

이미 쓴 집단 vs 안 쓴 집단

실험군 대조군



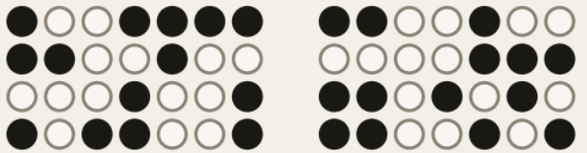
70% 30%

교란 통제 불가

무작위 배정

난수로 집단 결정

실험군 대조군



50% 50%

숨은 특성까지 균형

● 숨은 특성 있음 (예 : 동기 높음)

○ 없음

숫자 = 집단 안의 동기 높은 사람 비율 (모형 기댓값)

배정 · 2

자원자 비교의 함정



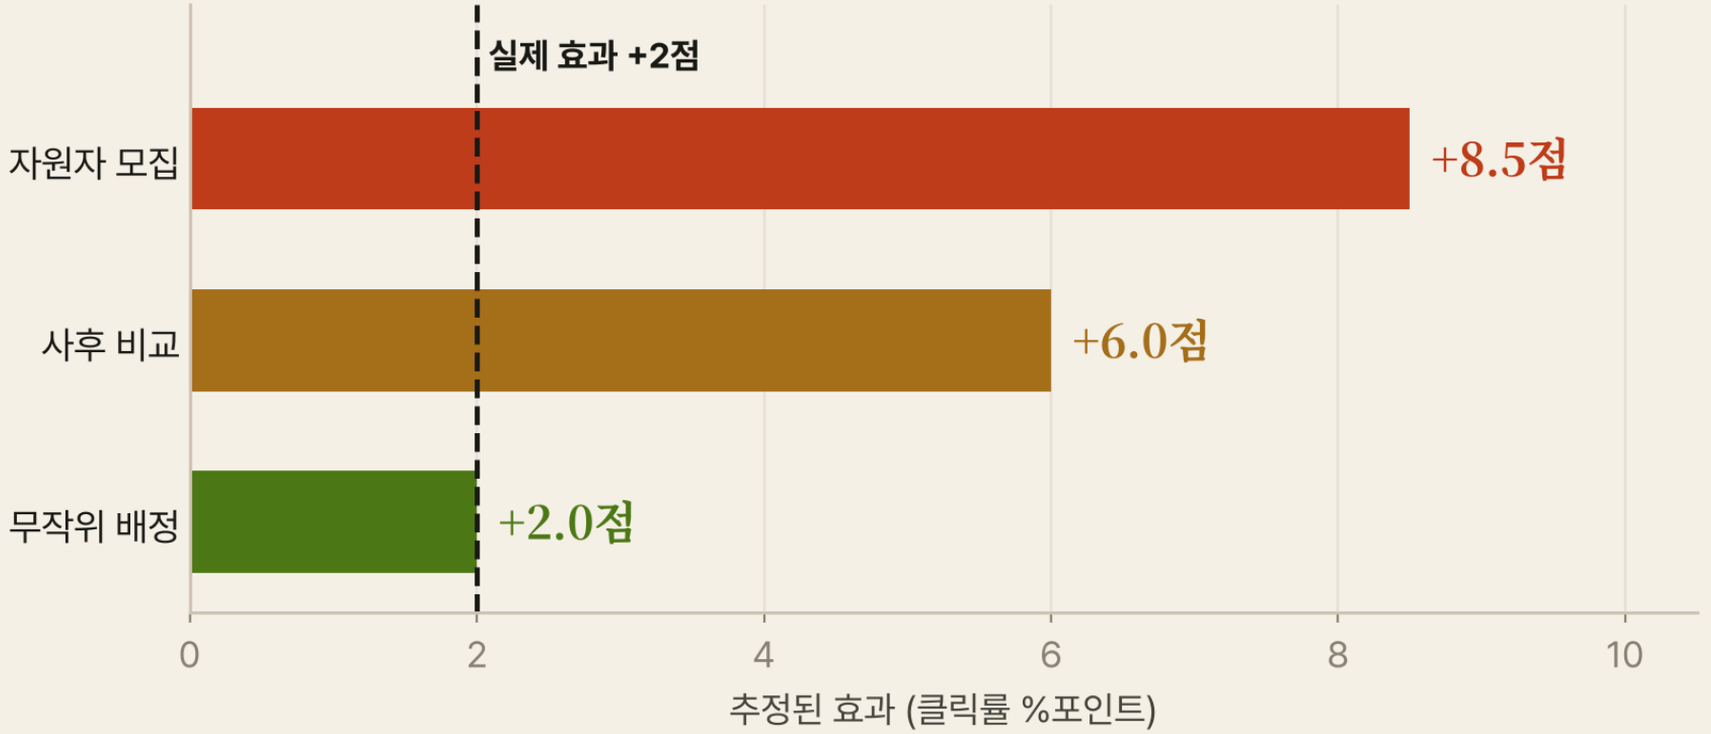
«새 공부법 신청자의 성적이 더 높음»

- 신청자 = 원래 의욕 높은 학생
- 공부법 없이도 성적이 높았을 가능성
- 효과와 의욕이 한 덩어리 → 분리 불가

같은 구조	섞여 있는 것
프리미엄 가입자 재구매율	원래 충성 고객
영양제 복용자 건강 수치	건강 관심 · 생활 습관
과외 수강생 성적	가정 환경 · 학습 동기

배정 · 3

방식별 추정 효과 : 실제 효과는 같음



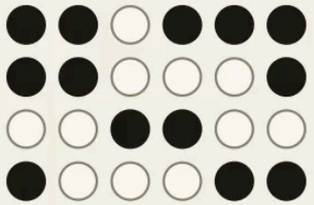
모형 · 동기 높은 사람은 클릭률 10점 더 높음 · 처치의 실제 효과 +2점 · 자원자 모집은 효과를 4배 넘게 과대 추정

배정 · 4 ★

동전 던지기가 숨은 특성까지 나누는 장면

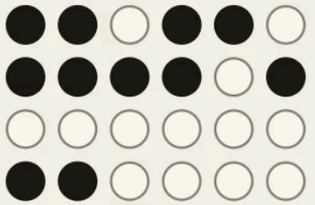
② 무작위 배정 : 한 명씩 동전 던지기

실험군



54%
동기 높은 사람 비율

대조군



46%
동기 높은 사람 비율

동전은 동기를 모름 → 측정 안 한 특성까지 비슷하게 분배

▶ 애니메이션 재생은 HTML 슬라이드에서

배정 · 5

무작위 배정의 효과

비유

제비뽑기 모둠 편성 : 키·성적·성격을 몰라도 인원이 많으면 양쪽 모둠이 비슷

- **알려진 교란** 균형 : 학년 · 기기 · 이용 빈도
- **숨은 교란** 균형 : 동기 · 기분 · 친구 영향
- 처치가 유일한 체계적 차이 → 인과 주장 가능
- 9주 문장 등급 «A가 B를 변화시킴»의 근거



주의 · 사람이 «대충 번갈아» 정한 배정은 무작위 아님 · 난수와 시드 기록 필요

배정 · 6

손으로 확인 : 12명 배정

학생	주당 공부시간	자원자 방식	제비뽑기
가 · 나 · 다	12 · 11 · 10	**실험 · 실험 · 실험**	대조 · 실험 · 대조
라 · 마 · 바	9 · 8 · 7	**실험 · 실험 · 대조**	실험 · 대조 · 대조
사 · 아 · 자	6 · 5 · 4	**실험 · 대조 · 대조**	대조 · 실험 · 실험
차 · 카 · 타	3 · 2 · 1	**대조 · 대조 · 대조**	실험 · 대조 · 실험

9.3 vs 3.7시간

자원자 방식 : 실험군 평균 vs 대조군 평균

5.5 vs 7.5시간

제비뽑기 : 실험군 평균 vs 대조군 평균

계산 · 자원자 실험군 (12+11+10+9+8+6)÷6 = 9.3 · 제비뽑기 실험군 (11+9+5+4+3+1)÷6 = 5.5 · 12명이면 차이 일부 잔존 · 뽑을 때마다 변동

배정 · 7 ★

배정 방식 비교기

인터랙티브 데모

이 자리에는 직접 조작하는 데모

HTML 슬라이드를 브라우저로 열어 확인

배정 · 8

배정 단위 : 누구를 한 칸으로 볼 것인가



기준 · 처치 경험이 섞이지 않는 가장 작은 단위 · 배정 단위와 분석 단위 일치 · 친구 사이 정보 전파 시 반·건물 단위 검토

6요소 · 1 ★

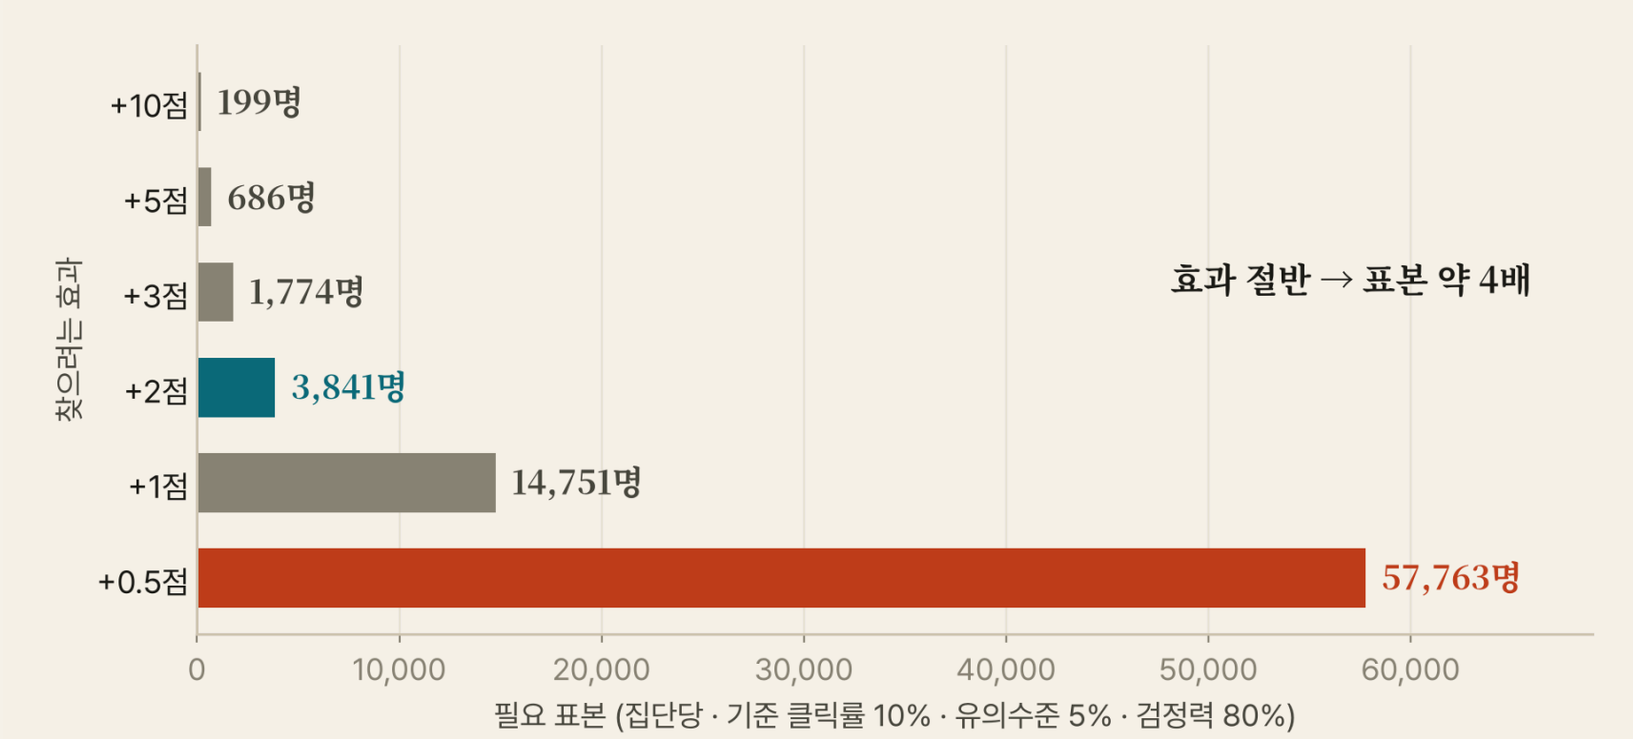
A/B 구성요소 6종 : 학식 쿠폰 앱 설계서

#	요소	질문	학식 쿠폰 앱 예
1	**대상**	누구에게 실험하는가	쿠폰 화면에 접속한 재학생
2	**배정 단위**	무엇을 한 칸으로 나누는가	학생 1명 · 첫 접속 때 고정
3	**처치**	무엇을 바꾸는가	A «쿠폰 받기» · B «오늘 점심 500원 아끼기»
4	**지표**	무엇으로 판단하는가	주 지표 클릭률 · 보조 지표 앱 종료율
5	**기간**	언제부터 언제까지인가	14일 · 요일 효과를 고려해 7일 단위
6	**표본 크기**	몇 명이 필요한가	집단당 3,841명 이상 (기준 10% · 찾을 효과 +2점)

> 6개 중 하나라도 빠지면 설계서 미완성 · AI 요청에도 6개 전부 포함

표본 · 1 ★

작은 차이일수록 필요한 사람 급증



비유 · 시끄러운 교실의 작은 목소리 → 더 오래 들어야 구분 · +10점 → +2점 : 효과 5분의 1, 표본 약 19배
용어 · 점 = %포인트 · 유의수준 5% = 효과 없을 때 «유의» 오판 비율 · 검정력 80% = 진짜 효과를 10번 중 8번 포착

표본 · 2

표본에서 기간으로

600명

하루 신규 방문 학생 (재방문 제외)

7,682명

필요 인원 = 3,841 × 2

14일

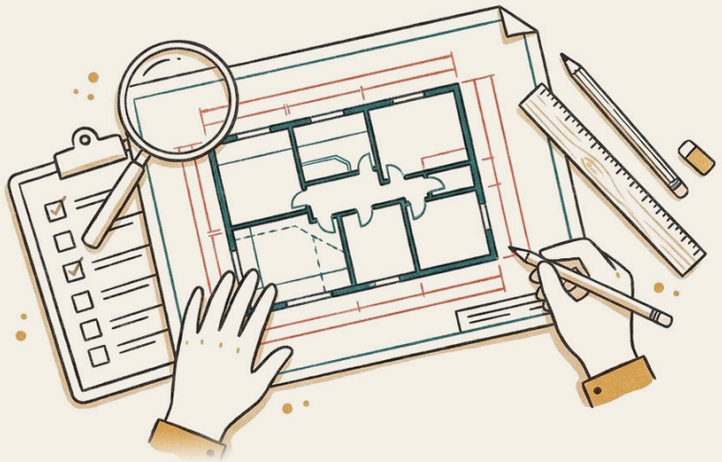
13일 필요 → 7일 단위 올림

찾을 효과	군당 인원	하루 600명 기준 기간	판단
+5점	686	3일 → 7일	가능
+2점	**3,841**	**13일 → 14일**	**이번 설계**
+1점	14,751	50일	학기 일정 확인
+0.5점	57,763	193일	**현실성 없음**

- 요일별 이용 패턴 차이 → 최소 1주 단위
- 찾을 효과 = 이 정도면 바꿀 가치가 있는 최소 크기
- 계산은 AI · 입력값 3개 제공은 사람

설계 · 1

사전 등록 : 시험 전 채점표 봉인



데이터를 보기 전에 기록할 것

주 지표	클릭률 1개
분석 방법	두 비율 차이 검정 · 양측 5%
기간·표본	14일 · 집단당 3,841명 이상
실질 기준	+2점 (바꿀 가치가 있는 최소 효과)
중단 규칙	오류·부작용 발생 시만 중단

비유

시험 전에 채점 기준 공개 · 답안 보고 기준을 바꾸는 일 차단

설계 · 2

실험 윤리 : 동의 · 위험 · 철회

질문	확인 내용
동의	참여 사실 안내 · 수집 항목 고지
위험	B안이 손해·불쾌감을 줄 가능성
철회	언제든 그만둘 방법
공정	가격 차별·건강·성적 불이익 여부

2014 페이스북 감정 실험 논란

약 69만 명 뉴스피드의 감정 게시물 노출 비율 조정 · 동의·이탈 기회 문제 제기

PNAS 게재 후 학술지가 «우려 표명»



PART II · 30분

이 실험,
믿어도 되는가

설계 점검표 · 사례 판정 · 지표 고르기 · AI 함정 #8

II

판단 · 1 ★

설계 점검표 5문

항목	합격	불합격 예
배정 절차	난수 · 시드 또는 코드 기록	**먼저 온 순서 · 담당자 임의 지정**
단위 일관	배정·측정·분석 단위 동일	**학생 배정 후 클릭 수 단위 분석**
지표 사전 정의	계산식까지 문장화	**결과 후 유리한 지표 선택**
기간 고정	시작일·종료일·요일 포함	**좋은 결과가 나온 날 종료**
중단 규칙	중단 조건 사전 명시	**"유의해지면 중단"**

판정 · 5개 모두 합격 시 실험 시작 · 표본 크기와 윤리는 설계서에서 별도 확인

판단 · 2

사례 판정 : 어디가 문제인가

#	사례	불합격 항목
1	«오전에 온 손님은 A 메뉴판, 오후 손님은 B 메뉴판»	**배정** · 시간대와 처치 혼합
2	«수업 A반은 새 교재, B반은 기존 교재 · 교수 다름»	**배정·조건** · 교수 차이 혼입
3	«클릭, 결제, 체류 중 좋아진 지표로 보고»	**지표** · 사후 선택
4	«3일째 B가 앞서기에 전체 적용»	**기간·중단** · 조기 종료
5	«앱 켤 때마다 버튼이 랜덤, 학생별 클릭률 분석»	**단위** · 같은 학생이 A·B 경험
6	«새 앱 설치 희망자 200명과 미설치자 200명 비교»	**배정** · 자원자 비교

판단 · 3

무엇을 지표로 삼을 것인가

허무 지표 (Vanity)

숫자가 커도 다음 행동이 불분명

예 : 누적 앱 실행 횟수 · 한 명의 재접속 100번도 합산

실행 가능 지표 (Actionable)

숫자를 보면 고칠 곳이 결정

예 : 쿠폰 화면 → 사용 완료 전환율 10% → 화면 문구 수정

역할	뜻	학식 쿠폰 앱
주 지표	성패를 가르는 숫자 1개	버튼 클릭률
보조 지표	원인 이해용	쿠폰 실제 사용률 · 체류 시간
가드레일	나빠지면 안 되는 숫자	앱 종료율 · 결제 취소율

실무 예 · 클릭률 상승 + 결제 취소 급증 = 낚시성 문구 신호 → 도입 보류

판단 · 4

A/B 테스트가 맞지 않는 경우

상황	문제	대안
방문자 하루 30명	표본 부족 · 수개월 소요	큰 변화만 시험 · 사용자 인터뷰 병행
한 지역만 시행한 정책	사람별 무작위 배정 불가	시행 전후 + 비슷한 지역 비교 (이중차분)
건강·안전 위험	윤리 문제	관찰 자료 분석 · 전문 심의
로고·브랜드 전면 교체	장기 효과 · 되돌리기 곤란	정성 조사 · 단계적 도입
친구 추천 기능	사용자끼리 영향 · 단위 오염	지역·학교 단위 배정

> 실험 불가 시 인과 주장 등급 하향 → «A가 B를 설명할 가능성» (9주 문장 등급)

AI 함정 #8

무작위 배정 없는 A/B

«A/B 테스트 설계해줘» 한 줄이 놓치는 것들

함정 #8 · 증상

한 줄 요청과 명세 요청

한 줄 요청

> 쿠폰 앱 A/B 테스트 설계해줘

흔한 응답

- 버튼을 바꾼 뒤 지난달과 비교
- 또는 신규·기존 사용자로 나눠 비교
- «클릭률이 오르면 성공»
- 배정 방법·기간·표본 크기 언급 없음

명세 요청

> 쿠폰 앱 A/B 설계서 작성.
6요소(대상·단위·처치·지표·기간·표본)를 표로.
배정은 학생 단위 난수 · 고정 방법을 코드로 제시.
기준 10%, 찾을 효과 +2점, 하루 600명으로 표본·기간 계산.
전후 비교·자원자 비교 금지. 빠진 정보는 질문.

함정 #8 · 원인과 진단

왜 생기고 어떻게 찾는가

원인

- 요청에 배정 절차·단위·기간·지표 없음
- AI는 쉽게 얻을 수 있는 데이터 쪽으로 제안
- 문장은 그럴듯 · 설계 요건 검사 없음

진단 순서

- 구성요소 6종 체크 · 빠진 칸 표시
- 배정 코드의 난수 호출 위치 확인
- 실제 배정 비율 50:50 근접 여부
- 사전 특성표로 두 집단 비교

> AI 답변의 **말투**가 아니라 **배정 절차**로 판정

함정 #8 · 코드

AI 코드에서 가장 자주 보는 배정 오류

문제 : 새로고침마다 버전 변경

```
// 화면을 열 때마다 동전 던지기
const variant =
  Math.random() < 0.5 ? "A" : "B";

showButton(variant);
log({ variant, event: "view" });
```

같은 학생이 A·B 모두 경험

방문자가 아닌 페이지뷰가 집계 단위로 변질

수정 : 첫 방문에만 결정 · 저장값 재사용

```
let visitor = load("ab_visitor");

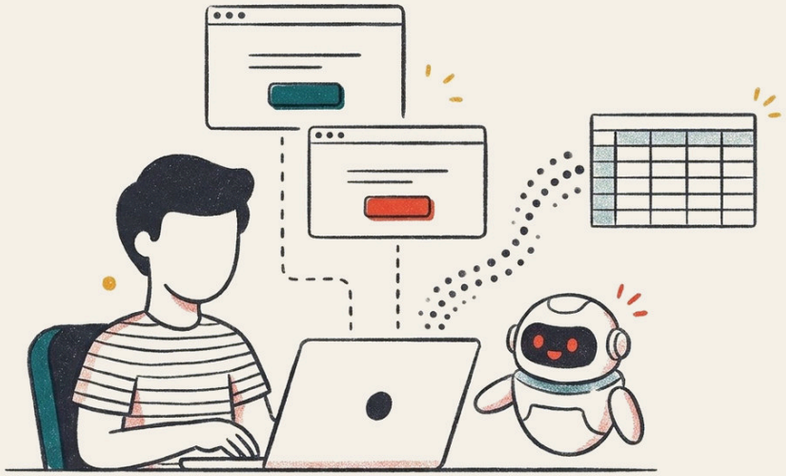
if (!visitor) {              // 처음 온 사람만
  visitor = {
    id: newId(),
    variant: Math.random() < 0.5 ? "A" : "B"
  };
  save("ab_visitor", visitor);
}
showButton(visitor.variant);
log({ id: visitor.id, variant: visitor.variant,
      event: "view" });
```

사람의 검증 · 새로고침 10번 → 버튼 문구 고정 여부 확인 · **한계** · 브라우저 저장 = 기기별 고정 · 실서비스는 로그인 ID 기준

PART III · 50분

바이브코딩으로 A/B 페이지 제작

코드 작성은 AI · 명세와 검증은 사람



실습 · 1

바이브코딩 작업 순환



도구 · OpenCode · Antigravity CLI 등 AI 코딩 에이전트 · 실행 결과는 브라우저에서 직접 확인

실습 · 2

이번 주 명세

[목표]
학식 쿠폰 A/B 페이지 1개 제작 · 방문자별 버전 고정 · 클릭 로그 CSV 저장

[제약]
- A 문구 «쿠폰 받기» · B 문구 «오늘 점심 500원 아끼기»
- 배정은 난수 · 방문자당 첫 접속 때 1회만 결정 · 브라우저에 저장
- 실제 개인정보 입력칸 금지 · 방문자 번호는 임의 생성

[검증 조건]
- 새로고침 10회에도 같은 버전 유지
- «새 방문자» 버튼 → 새 번호와 새 배정
- 가상 방문자 1,000명 생성 시 A·B 비율 45~55%
- CSV 열 : id, variant, clicked, time · 방문자 1명당 1행

[비목표]
- 로그인, 서버 저장, 디자인 꾸미기, 유의성 검정(11주)

샘플 · 완성 예시 data/ab-sample · 실습 후 비교용

실습 · 3

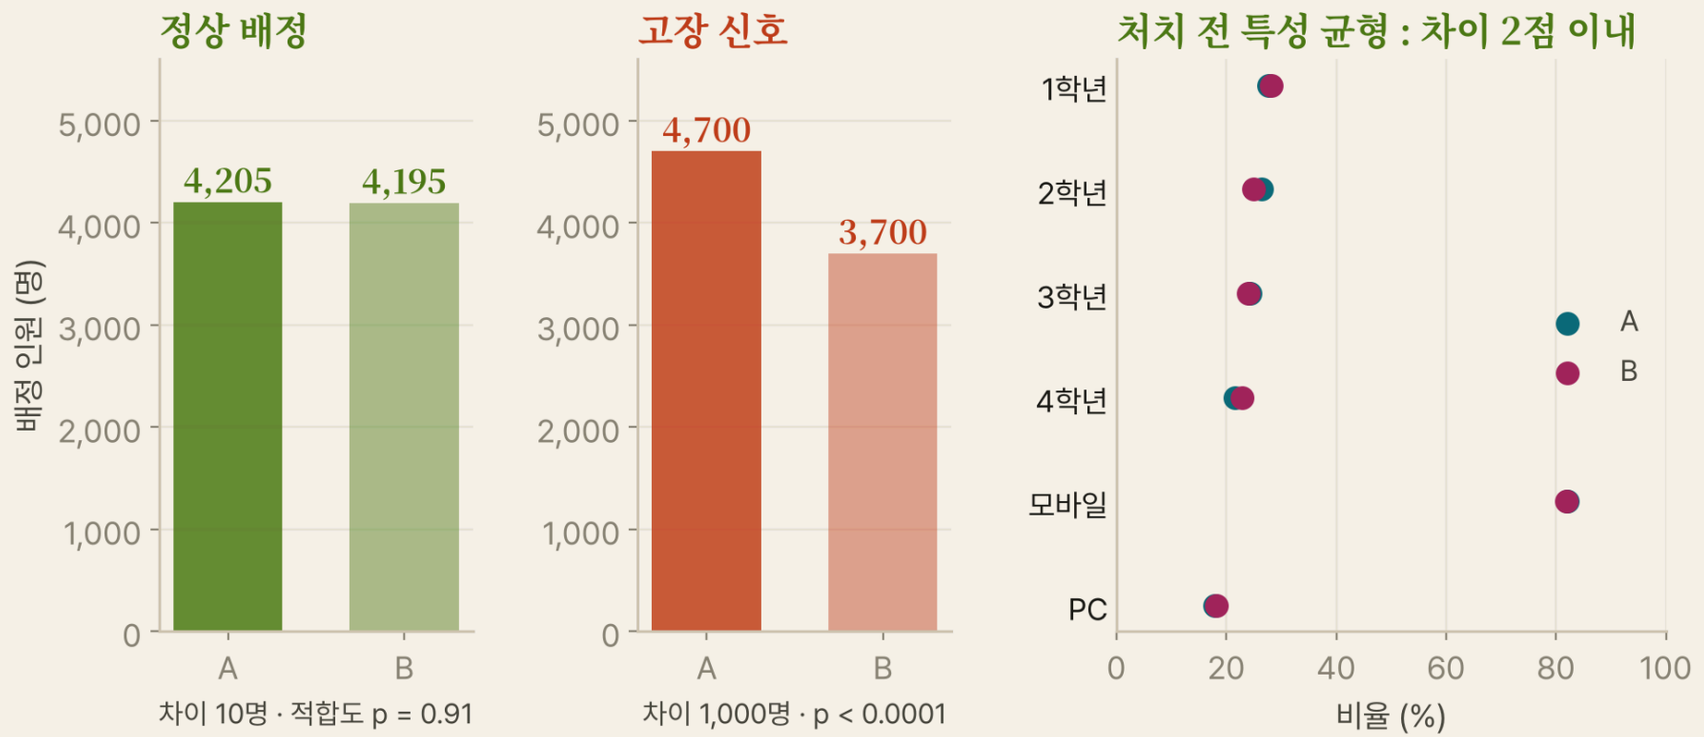
오늘의 실습 — 50분

#	활동	개념
1	«A/B 테스트 설계해줘» 요청 → 빠진 항목 목록화	함정 #8
2	구성요소 6종 명세로 재요청 → 결과 비교	설계 요건
3	위 명세로 페이지 제작 → 난수 배정·균형 확인	무작위 배정
4	찾을 효과 +1 · +2 · +5점의 표본과 기간 비교	표본 크기
5	확장 : 중단 규칙·기간 사전 확정 문서 작성	사전 등록

합격 조건 · 새로고침 10회 고정 · 배정 비율 45~55% · CSV 행 수 = 방문자 수 · **제출** · 명세 · AI 대화 · 검증 화면

실습 · 4

배정 점검 : 코드를 몰라도 가능한 검증



확인할 파일 · ab_result.csv 8,400명 · 50:50에서 크게 벗어나면 결과 해석 전에 배정·로그부터 점검 (SRM : 표본 비율 불일치)

과제

공식 과제 : 일상 속 A/B 테스트 설계

설계서 항목	작성 기준
질문·가설	H_0 · H_1 문장
구성요소 6종	표로 작성 · 칸 비움 금지
배정 방법	난수 도구 · 고정 방법
사전 등록	주 지표 1개 · 중단 규칙
윤리 점검	동의 · 위험 · 철회

예시 주제

동아리 모집 포스터 · 과제 알림 문구 · 카페 메뉴판 · 공부 시간대 · 쇼츠 썸네일

채점

명세 구체성 · 배정 타당성 · 표본 계산 근거 · AI 사용 기록

실행 여부 · 실제 실험 진행 불필요 · 11주에 모의 결과로 해석 연습

정리

한 장 요약

개념	핵심
전후 비교	시기 효과와 처치 효과 구분 불가 → 동시 대조군 필요
가설	H_0 차이 없음 · H_1 차이 있음 · 데이터 수집 전 선언
실험군·대조군	처치 외 조건 동일 · 같은 기간 동시 운영
무작위 배정	알려진 교란 + 숨은 교란 동시 균형 · 자원자·사후 비교는 과대 추정 위험
배정 단위	처치 경험이 섞이지 않는 단위 · 앱 실험은 대개 사람 1명 고정
구성요소 6종	대상 · 단위 · 처치 · 지표 · 기간 · 표본 크기
표본 크기	효과 절반 → 표본 약 4배 · 기준 10% · +2점 = 집단당 3,841명
사전 등록·윤리	주 지표·방법·중단 규칙 사전 기록 · 동의 · 위험 · 철회
AI 함정 #8	사후 비교 제안 · 새로고침마다 랜덤 → 6종 명세 · 고정 배정 · 비율 점검

다음 주

A/B 결과와 p값

B가 앞선 결과 · 진짜 효과인가 우연인가

학식 쿠폰 실험 결과표로 해석 연습