WEEK 11

A/B 결과 읽는 법

표본 변동 · p값 · 효과 크기 · 신뢰구간
비전공자를 위한 결과 해석과 AI 검증



데이터리터러시의이해 SF1101084 · AI융합교육원
조성호 · 2026학년도 2학기

도입 질문

A/B 테스트 결과 $p = 0.03$

효과가 확실한가?
효과가 없을 확률이 3%인가?

도입

학습 목표

① 해석

표본 변동 · p값의 **정확한 뜻**

오해 3종 구분

효과 크기와 신뢰구간 읽기

② 판단

다중 비교 · 중간 확인의 위험

보고 4종으로 주장 범위 결정

도입 · 보류 · 재실험 판단

③ 검증

«유의미합니다» 단정 AI 답변 재요청

손계산으로 결과 대조

효과 0 데이터로 거짓 양성 체험

수학 수준 · 고등학교 평균과 비율 · 5주 z-점수까지만 사용 · 나머지 계산은 AI 담당 · 사람은 검산과 해석

PART I · 60분

차이가 보일 때
먼저 의심할 것

표본 변동 → p값 → 효과 크기 → 신뢰구간
→ 반복의 함정





결과 · 1

10주 학식 쿠폰 실험 결과 도착

버전	문구	배정 인원	클릭	클릭률
A	«쿠폰 받기»	4,205명	422명	**10.04%**
B	«오늘 점심 500원 아끼기»	4,195명	486명	**11.59%**

+1.55점

차이 (%포인트)

?

진짜 효과인가 · 이번 표본의 우연인가

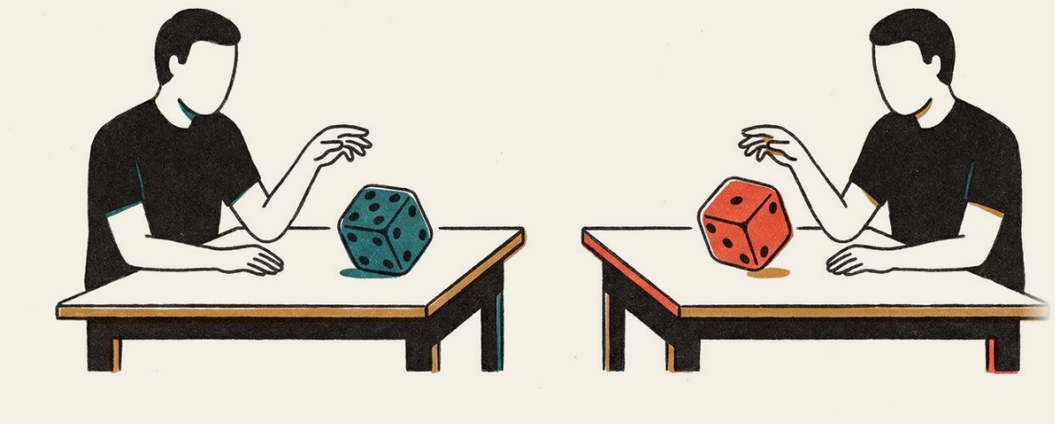
?

도입할 만한 크기인가

데이터 · ab_result.csv · 14일 · 8,400명 · 교육용 합성 데이터 · 실제 집단 특성 해석 금지

표본 변동 · 1

같은 조건을 반복해도 결과는 변동



비유

주사위 : 같은 주사위 60번 → 6이 나온 횟수 사람마다 상이 · 주사위 차이 아님

A/A 실험 : 똑같은 버튼 2개 비교 (집단당 500명)

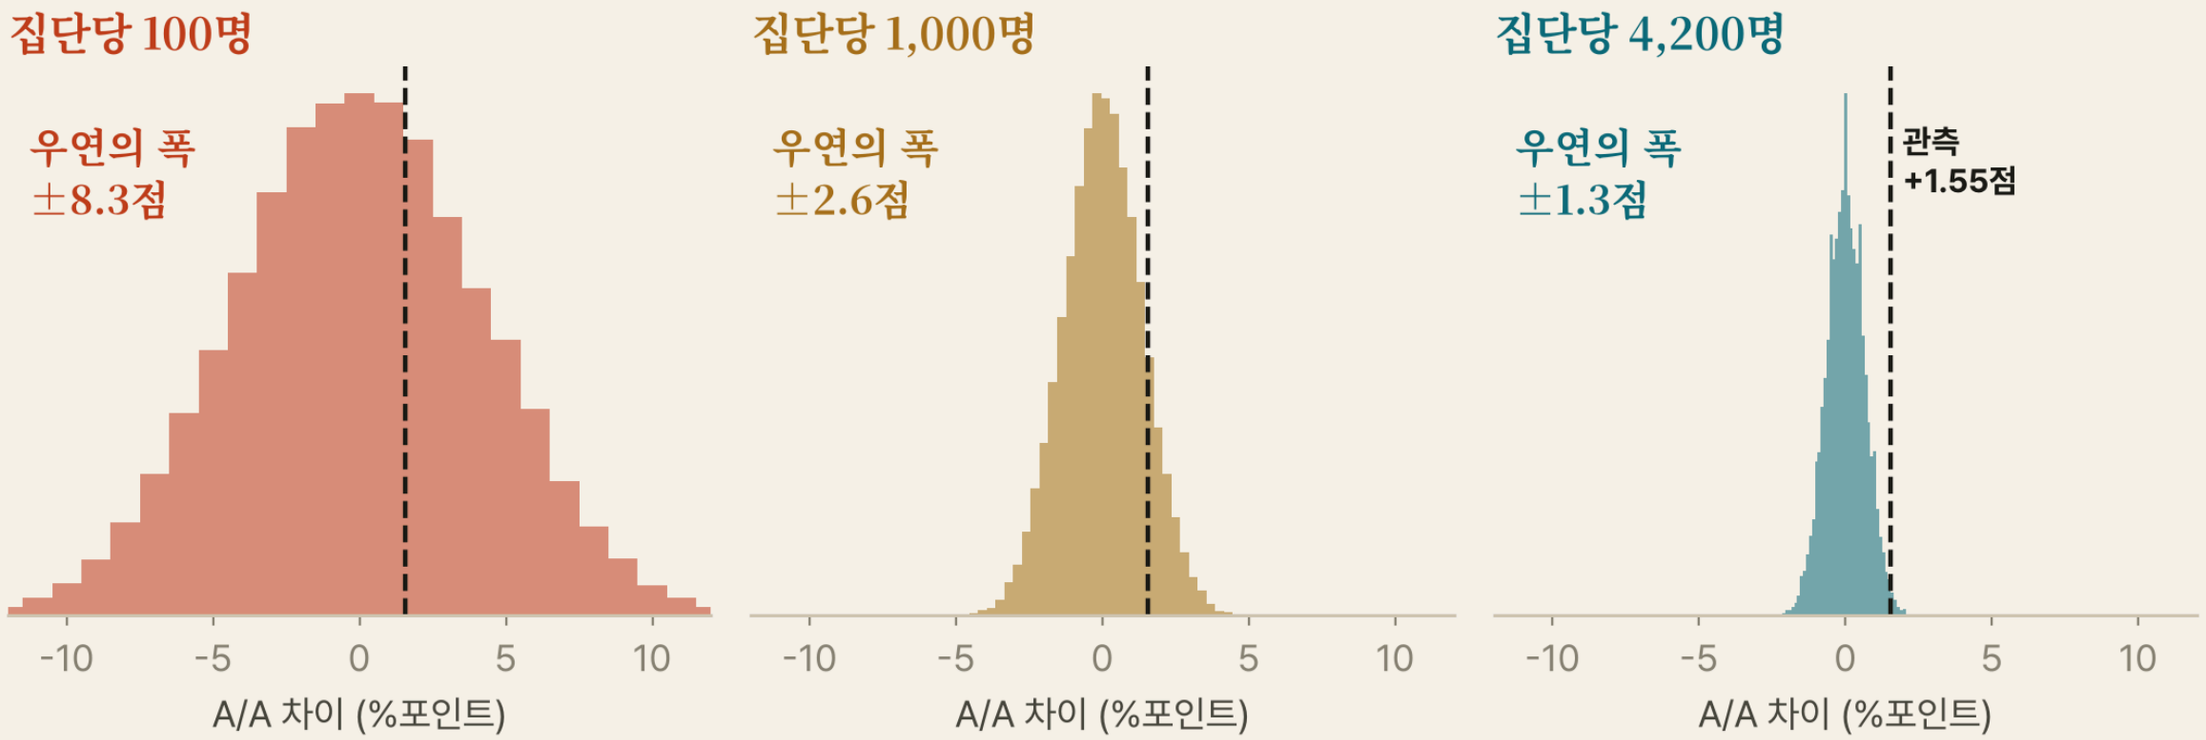
회차	1	2	3	4	5	6	7	8
차이	+1.0	−0.2	**+2.2**	−1.0	+1.0	−0.8	**−2.6**	**−3.0**

효과 0 인데도 3점 차이 발생

핵심 · 차이의 크기만으로 판단 불가 → «우연으로 어느 정도까지 가능한가»와 비교 필요

표본 변동 · 2 ★

표본이 클수록 우연의 폭 감소



점선 · 관측 차이 +1.55점 · 집단 100명이면 우연으로 흔한 차이 · 집단 4,200명이면 우연의 폭 바깥

P값 · 1

p값 비유 : 콜라 맞히기

친구의 주장 : «콜라 두 브랜드 구분 가능»

- 8잔 중 4잔씩 무작위 제공 · 친구도 4잔씩임을 인지
- 친구가 8잔 전부 정답

반대 입장에서 계산

- 가정 : 친구는 구분 못 함 = 찍기
- 4잔 고르는 경우의 수 = 70가지
- 전부 정답 = 1가지 → **1.4%**

> 찍기로는 드문 결과 → «찍기» 가정 의심



P값 · 2 ★

p값의 정의



> **차이가 없다고 가정했을 때**
> 지금만큼 또는 더 큰 차이가 나올 확률

재판	A/B 테스트
무죄 추정	귀무가설 : 차이 없음
증거 수집	실험 데이터
무죄라면 이런 증거가 나올 확률	p값
유죄 판결	귀무가설 기각 (유의)
증거 불충분 ≠ 결백 입증	유의하지 않음 ≠ 효과 없음

P값 · 3 ★

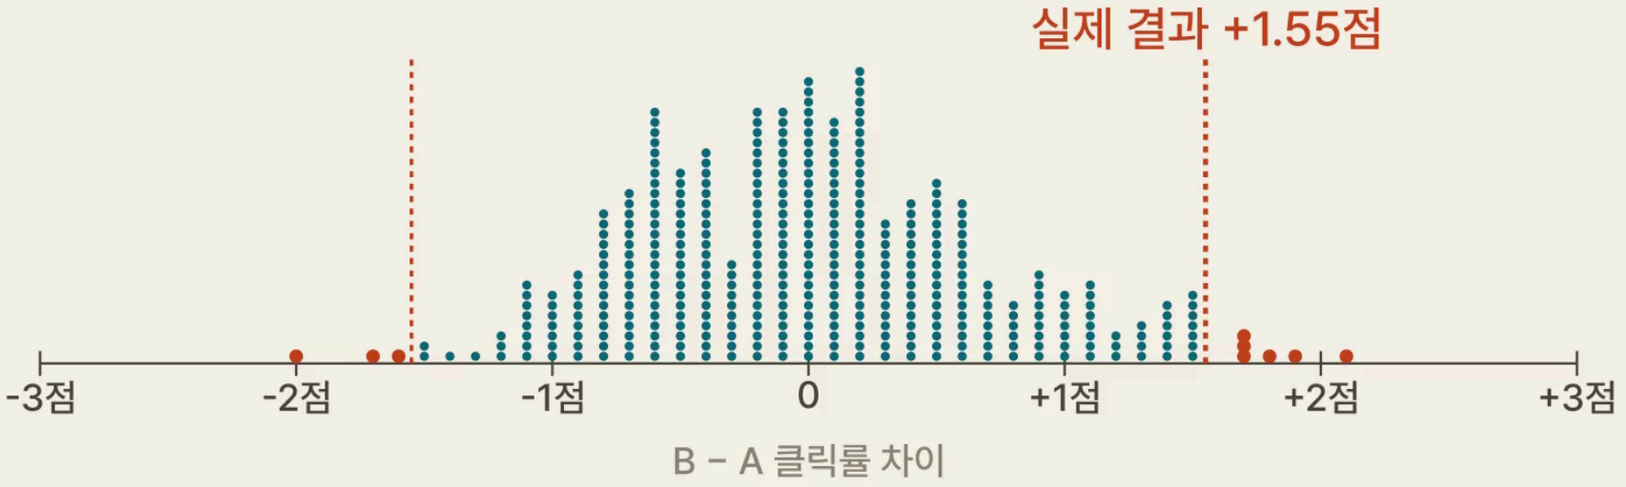
효과 0 세계를 직접 만들어 본 결과

같은 버튼 2개로 실험 반복 (효과 0)

집단당 4,200명 · 실험 1회 = 점 1개

바깥 점 9개 / 400회 ≈ 2.2%

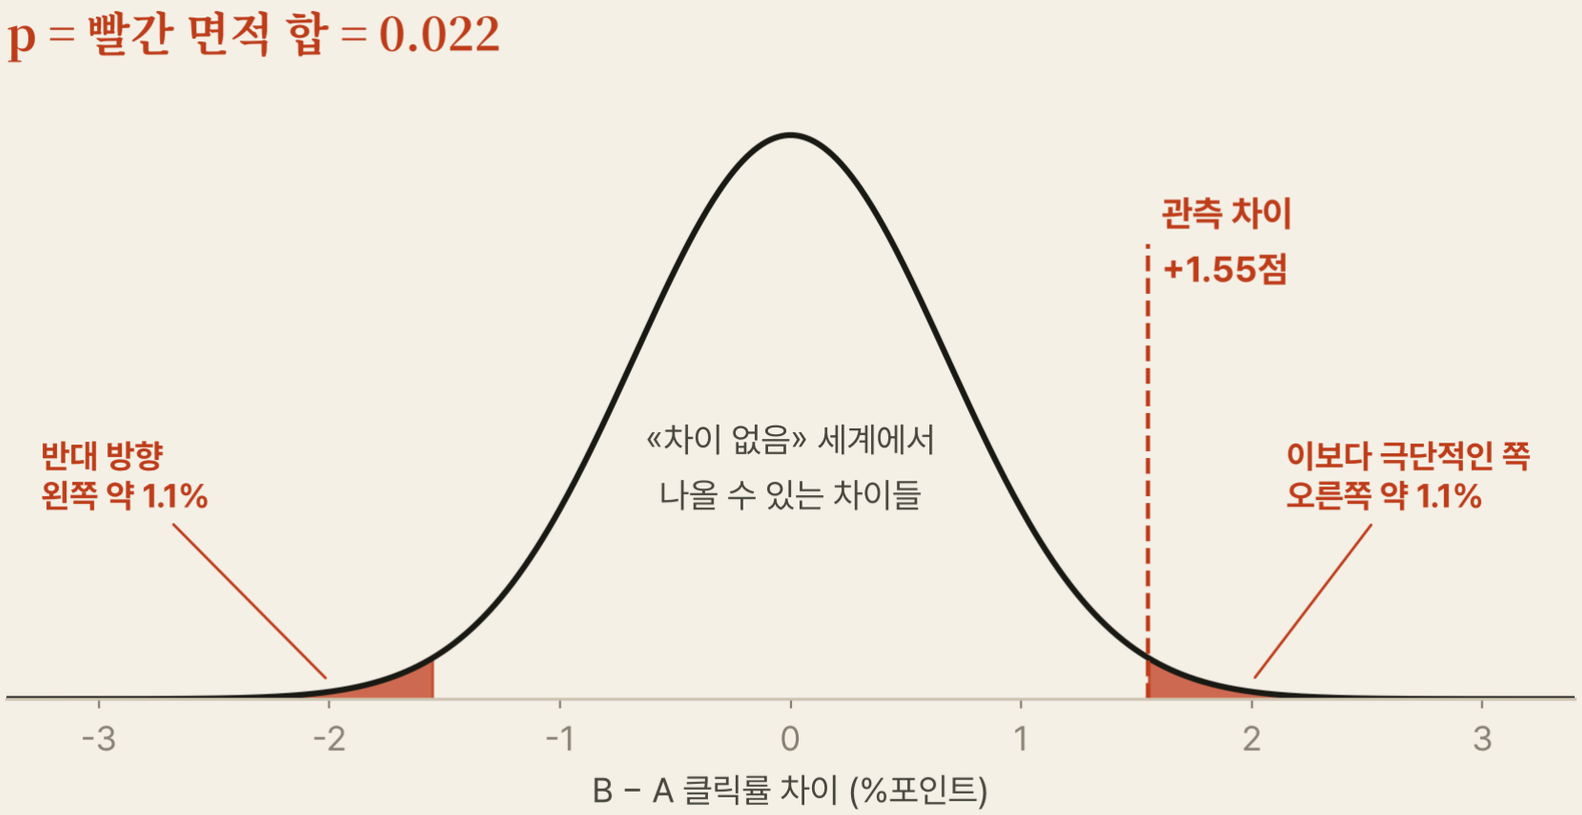
수식 계산값 p = 0.022



▶ 애니메이션 재생은 HTML 슬라이드에서

P값 · 4

수식으로 그린 같은 그림



양측 검정 · B가 나쁠 가능성도 함께 고려 → 오른쪽 꼬리와 왼쪽 꼬리 합산

P값 · 5

손계산 : 5주 z-점수의 응용

#	단계	계산
1	전체 클릭률	(422+486) / 8,400 = 10.81%
2	우연의 크기 (표준오차)	√[0.1081 × 0.8919 × (1/4205 + 1/4195)] = 0.678점
3	z값	1.55 ÷ 0.678 = **2.29**
4	p값 (양측)	z 표 또는 AI 계산 → **0.022**

5주와 같은 구조

z-점수 =

(값 − 평균) ÷ 표준편차

A/B z값 =

(관측 차이 − 0) ÷ 표준오차

«우연의 눈금 몇 칸 떨어졌는가»

암기 대상 아님 · 공식은 AI 담당 · 사람의 역할은 입력값(n·클릭 수) 확인과 결과 검산

P값 · 6 ★

흔한 오해 3종 : 전부 오답

오해	실제
«p = 0.03 → 효과가 없을 확률 3%»	«효과 없음»을 참으로 가정하고 계산한 값 가설이 참일 확률 계산 아님
«p가 작을수록 효과가 큼»	표본이 크면 작은 효과도 p 작음 효과 크기는 별도 확인
«p = 0.03 → 다시 하면 97% 재현»	재현 확률 아님 재현은 추가 실험으로 확인

도입 질문 답 : 확실성 보증 아님 · «차이 없음» 가정 아래 드문 결과일 뿐

P값 · 7

0.05 : 자연법칙이 아닌 관행

결과	기계적 판정	실제 증거 차이
p = 0.049	유의	거의 동일
p = 0.051	비유의	

분야	흔한 기준
사회과학·제품 실험	0.05
유전체 전장 분석	5×10^{-8}
입자 물리학 발견	5σ (약 3×10^{-7})

	불 없음	불 있음
경보 울림	1종 오류 거짓 양성 (α)	정상 탐지 검정력 (1−β)
경보 조용	정상	2종 오류 거짓 음성 (β)

비유

화재경보기 : 민감하게 설정 → 오작동 증가 · 둔하게 설정 → 화재 놓침

실무 기본값 · α 5% · 검정력 80% · 실패 비용에 따라 조정 · 값은 실험 전에 고정

크기 · 1 ★

유의함과 중요함은 별개

집단 100만 명 실험

A 클릭률	10.0%
B 클릭률	10.1%
차이	**+0.1점**
p값	**0.019 (유의)**



비유

거대한 현미경 : 개미도 선명하게 포착 · 개미 크기와 무관

실무 질문 · 이 차이가 개발·운영 비용보다 큰가 · 사용자에게 체감되는가

크기 · 2

결과의 네 가지 조합

	실질 효과 큼	실질 효과 작음
$p < 0.05$	**실질 효과 작음 · 유의** 집단 100만 명 · +0.1점 · p=0.019 → 비용 대비 판단 → 대개 보류	**실질 효과 큼 · 유의** 집단 1만 명 · +3점 · p<0.001 → 도입 후보
$p \geq 0.05$	**효과 커 보임 · 비유의** 집단 100명 · +3점 · p=0.506 → 판단 불가 → 표본 재계산 후 새 실험	**실질 효과 작음 · 비유의** 표본 충분 · 구간도 좁음 → 중단 · 다음 아이디어

구간 · 1

신뢰구간 : 한 점이 아닌 범위로 말하기

비유

그물 낚시 : 작살 한 번(점 추정)보다 그물(구간)의 포착 가능성 큼 · 그물이 넓을수록 불확실성 큼

```
효과 = +1.55점
95% 신뢰구간 = +0.22 ~ +2.88점
```

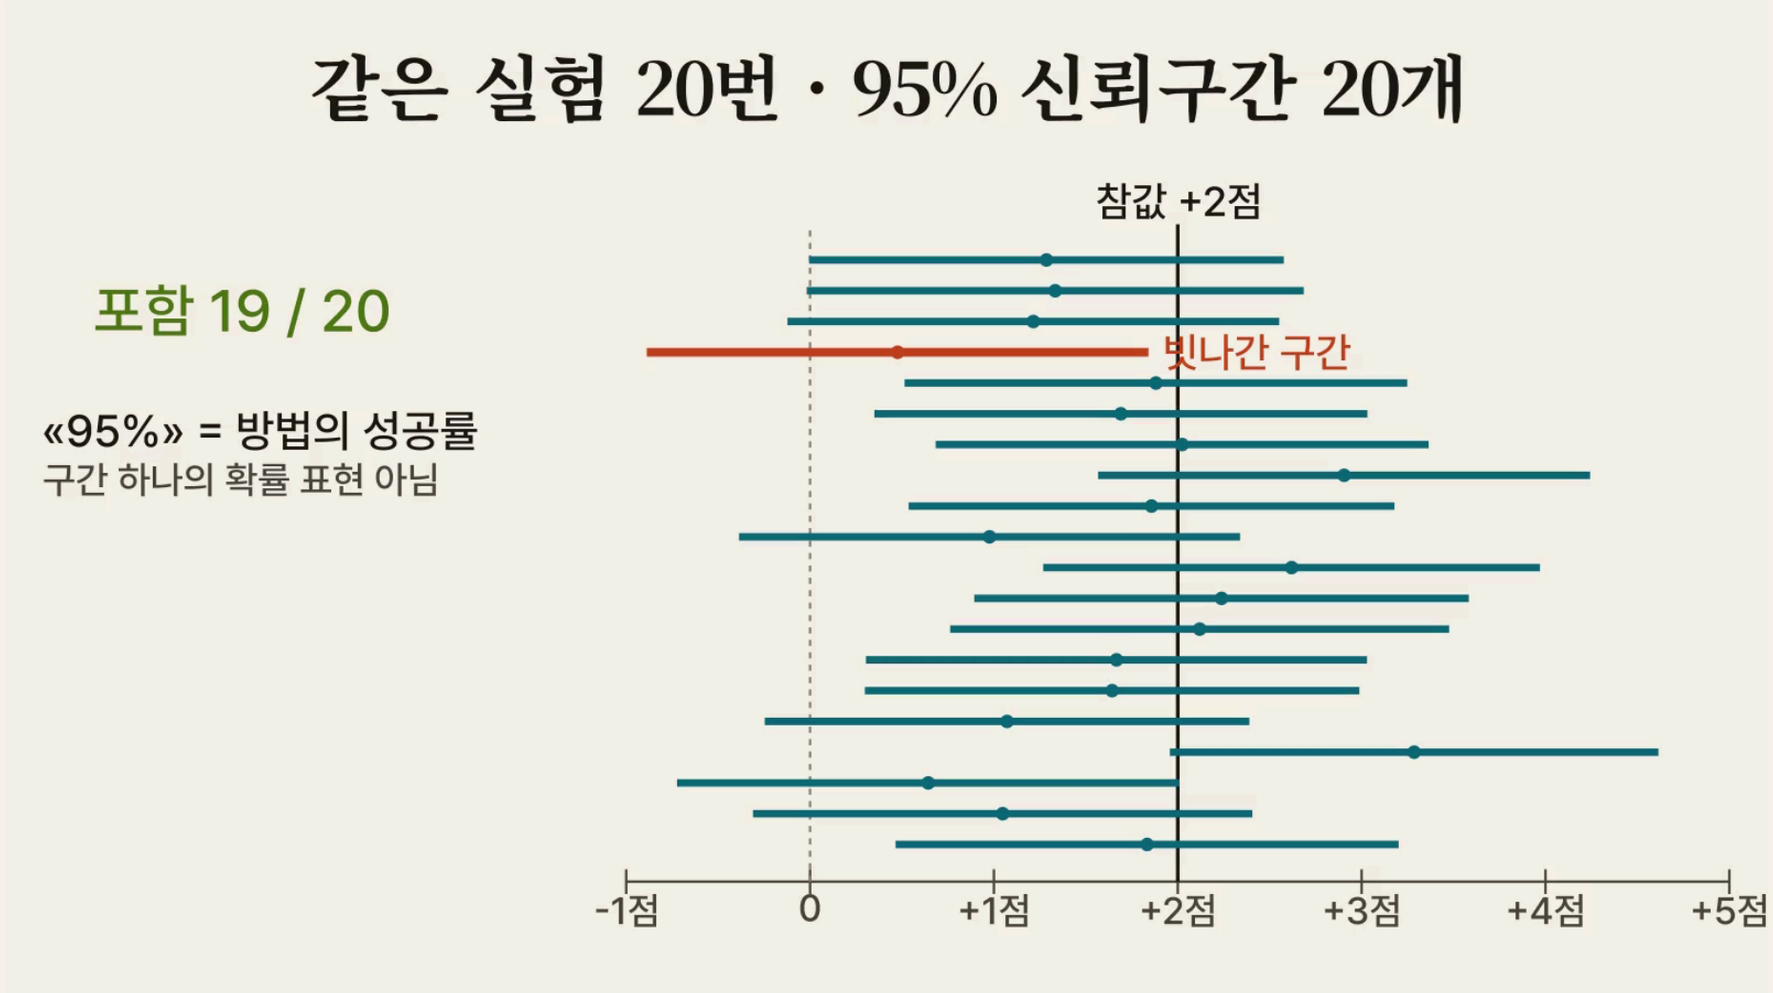


- **0 미포함** → p < 0.05 와 같은 판단
- **폭** → 추정의 정밀도
- **하한·상한** → 데이터와 잘 맞는 효과 범위 · 구간 밖일 가능성도 남음

쉬운 문장 · «클릭률 차이는 대략 +0.2점에서 +2.9점 사이로 추정»

구간 · 2 ★

«95%»의 뜻 : 같은 방법을 20번 반복



▶ 애니메이션 재생은 HTML 슬라이드에서

구간 · 3 ★

표본과 효과에 따라 달라지는 구간



읽는 순서 · ① 0을 포함하는가 ② 실질 기준선과 어떤 관계인가 ③ 폭이 판단에 충분히 좁은가

반복 · 1

다중 비교 : 많이 쏘면 언젠가 명중



비유

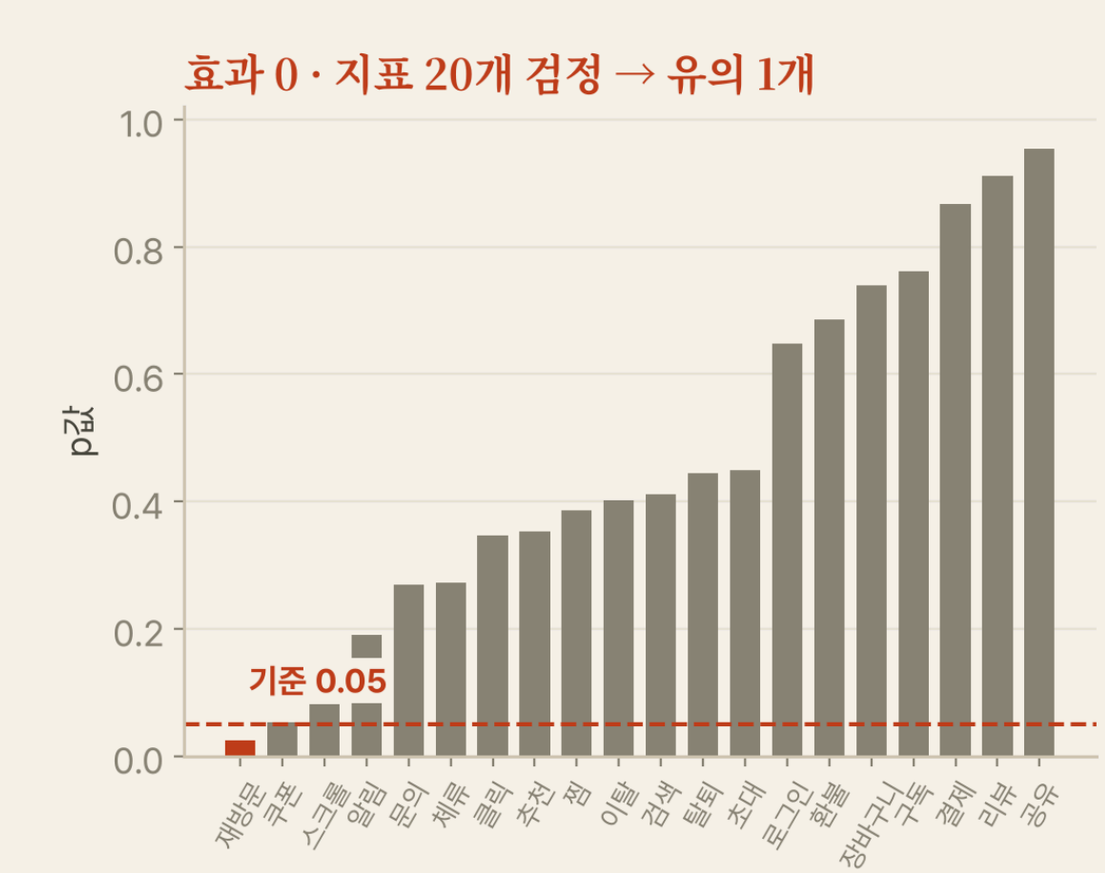
과녁 20개에 다트 투척 : 맞힌 과녁 하나만 보여 주면 명사수처럼 보임

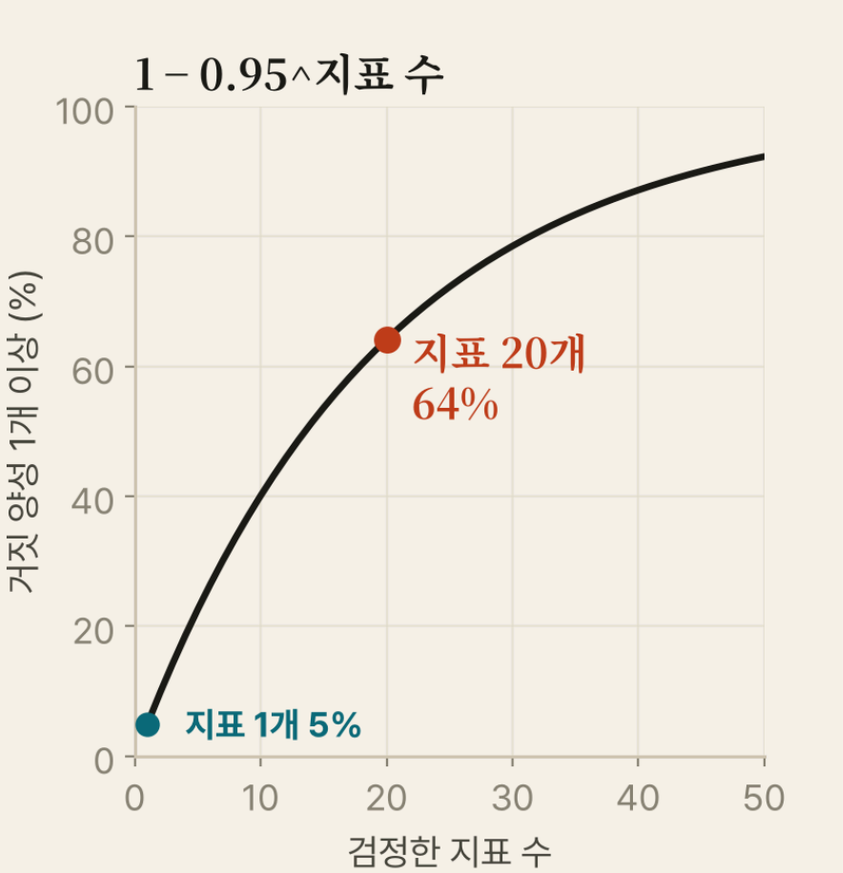
검정 지표 수	우연 유의 기대	1개 이상 발생 (지표 독립 시)
1개	0.05개	5%
5개	0.25개	23%
20개	**1개**	**64%**

간단 보정 (본페로니) : 0.05 ÷ 지표 수 → 20개면 기준 0.0025

반복 · 2

효과가 0이어도 지표를 늘리면 무언가는 «유의»





반복 · 3 ★

중간 확인 : 이기는 순간 휘슬 불기

비유

축구 경기 : 우리 팀이 앞설 때마다 경기 종료 가능 → 약팀도 승률 상승

- 실험 중 p값은 오르내림이 자연스러운 현상
- 0.05 아래로 들어온 순간 종료 → 거짓 양성 누적
- 학식 쿠폰 p값 : 8일 차 0.035 → 10일 차 0.052 → 14일 차 0.022



대시보드 시청은 가능 · 그 값으로 종료 결정 금지

반복 · 4 ★

효과 0 실험 40개를 매일 들여다보면

효과 0 실험 40개를 매일 확인

확인 14일 차

9개

중간에 «유의» 종료

끝에 1번만 확인

2개

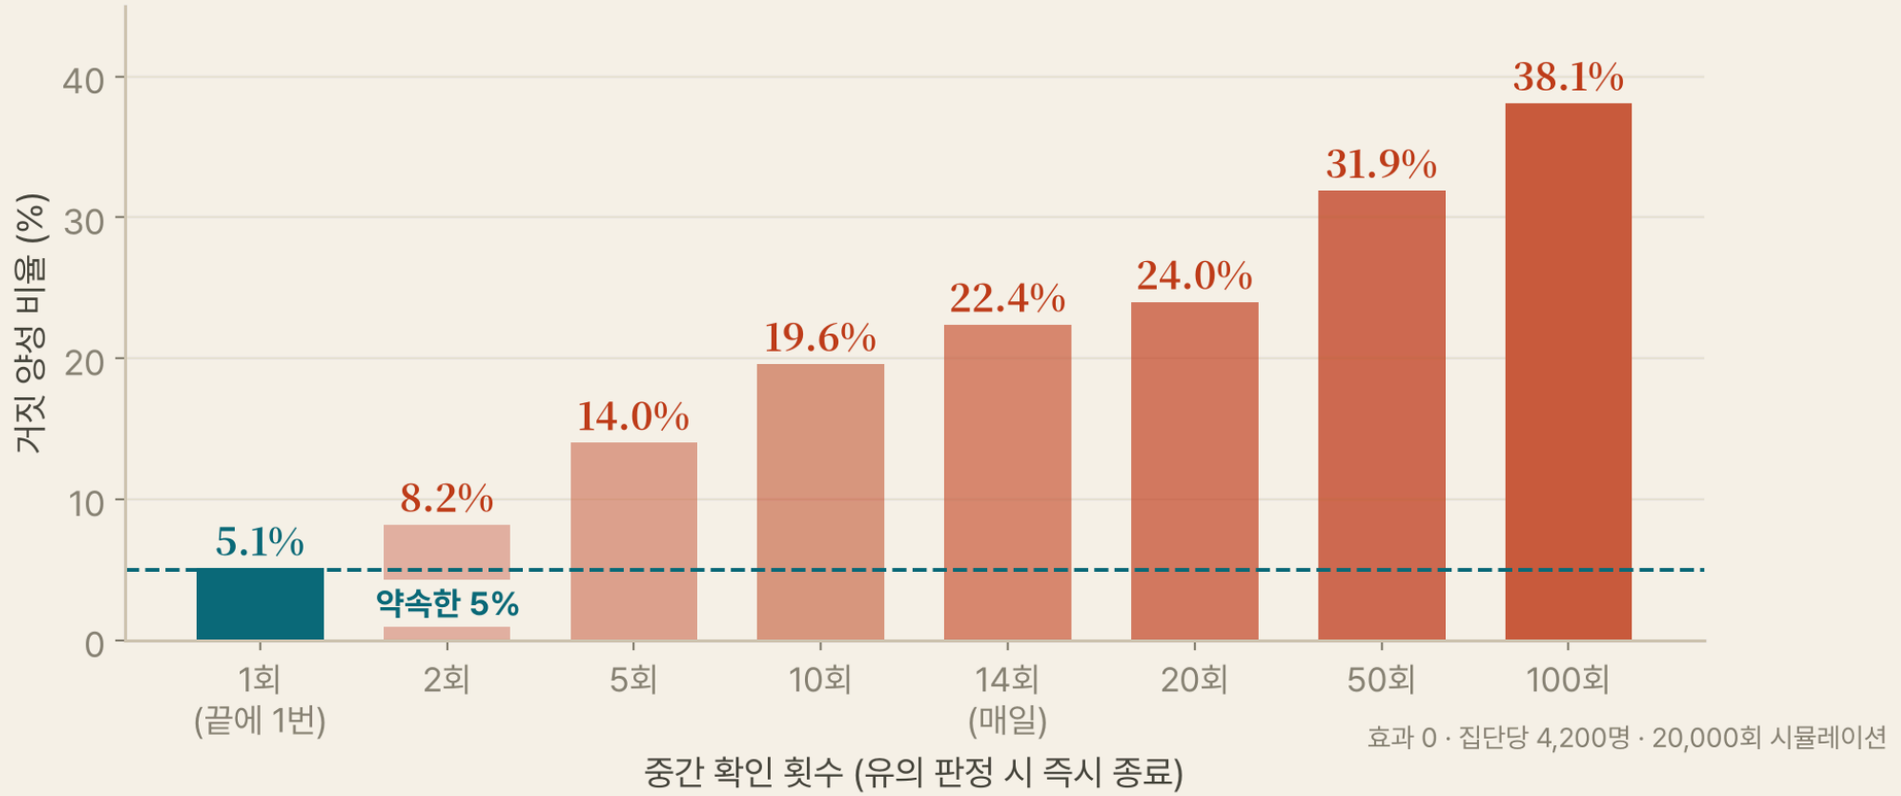
약속한 5% = 2개



▶ 애니메이션 재생은 HTML 슬라이드에서

반복 · 5

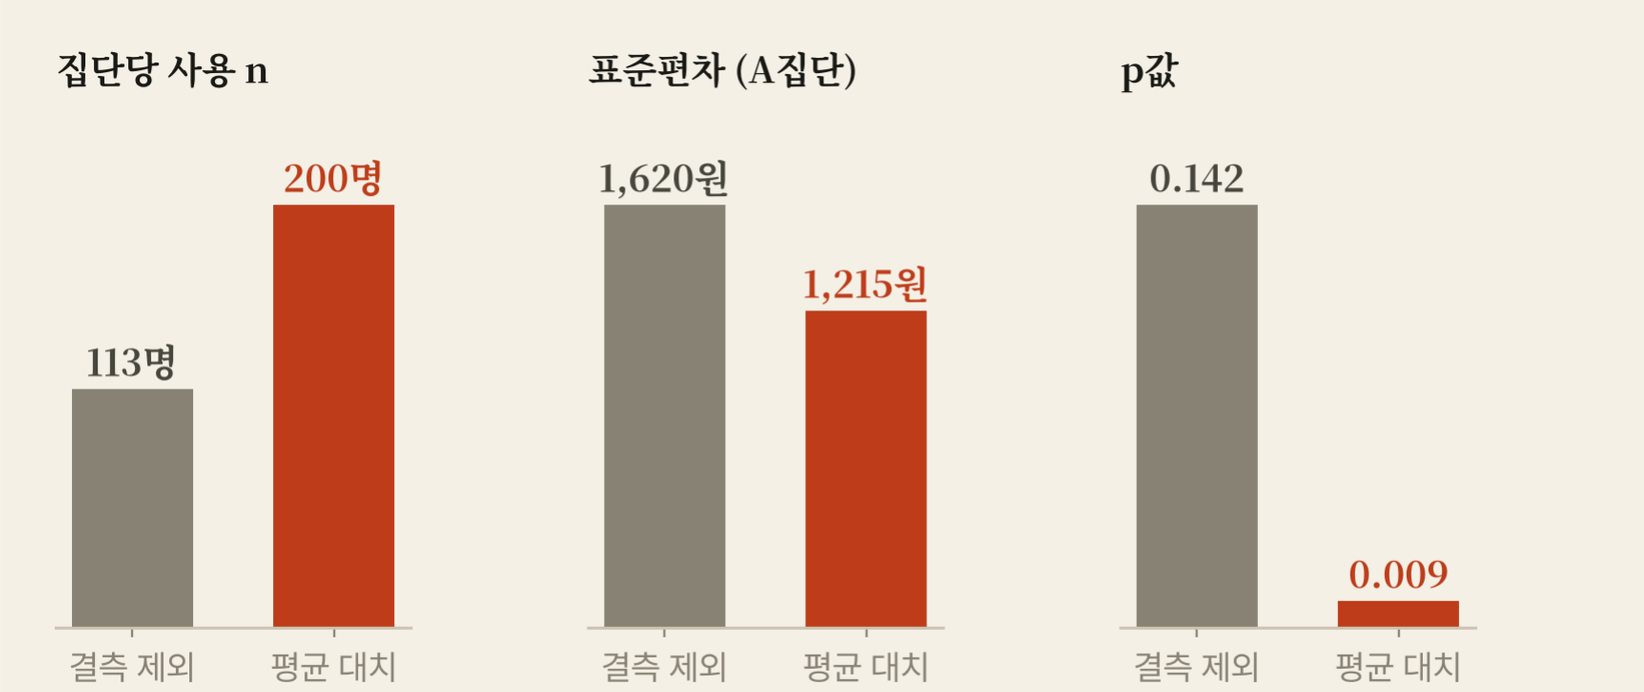
확인 횟수별 거짓 양성



처방 · 기간·표본 사전 고정 · 중단은 오류·부작용 때만 · 중간 판단이 꼭 필요하면 순차 검정 등 전문 방법 사용

반복 · 6

3주 연결 : 결측을 평균으로 채우면 쉬워지는 «유의»



지출액 지표 · 결측 약 44% · 관측값 평균 차이 297원 동일 · 교육용 합성 데이터

원인 · 평균값 복제 → 표본 수 증가처럼 보임 + 표준편차 감소 → 우연의 눈금 축소 → p값 하락 · 새 정보 추가 없음

시뮬레이터 ★

유의성 시뮬레이터

인터랙티브 데모

이 자리에는 직접 조작하는 데모

HTML 슬라이드를 브라우저로 열어 확인

PART II · 30분

결과를
보고하고 결정하기

보고 4종 · 판단 문장 · 도입 결정표



판단 · 1 ★

보고 4종

항목	왜 필요한가	학식 쿠폰 앱
효과 크기	실제로 얼마나 다른가	+1.55점 (10.04% → 11.59%)
신뢰구간	얼마나 불확실한가	95% CI +0.22 ~ +2.88점
n	근거의 크기	A 4,205명 · B 4,195명
검정 횟수	우연 유의 가능성	주 지표 1개 · 기간 종료 후 1회

> $p = 0.022$ 는 위 네 줄의 **보조 정보** · 단독 보고 금지

판단 · 2

판단 문장 고치기

단정

«p<0.05 이므로 B가 확실히 더 좋습니다.»

«유의하지 않으므로 효과가 없습니다.»

«차이가 우연일 확률은 2.2%입니다.»

주장 범위 명시

«14일 · 8,400명 실험에서 B의 클릭률이 1.55점 높게 관측 (95% CI +0.22~+2.88).»

«이번 표본으로는 차이를 확인하지 못함. 효과 없음 입증은 아님.»

«차이 관측 · 실질적 의미는 별도 판단.»

9주 문장 등급 연결 · 무작위 실험이면 인과 표현 가능 · 대상과 기간 범위 안에서만 · 다른 앱·다른 학기로 일반화 금지

판단 · 3

확증 결과와 탐색 결과

확증 결과

사전 등록한 주 지표 1개

기간 종료 후 1회 검정

보고 문구 : «확증 분석»

예 : 클릭률 차이 +1.55점

탐색 결과

실험 후 찾아낸 지표·세부 집단

유의해도 다음 실험의 가설로만 사용

보고 문구 : «탐색 분석 · 재검증 필요»

예 : «4학년 모바일에서 효과 큼»

비유

모의고사 복습 : 틀린 유형 발견(탐색) → 다음 시험에서 확인(확증) · 복습 중 발견을 실력 향상의 증거로 제출 불가

판단 · 4 ★

도입 결정표

신뢰구간 위치	예 (실질 기준 +2점)	결정	다음 행동
전부 실질 기준 위	+2.1 ~ +3.9	**도입**	단계적 배포 · 지표 모니터링
0 위 · 실질 기준 걸침	**+0.22 ~ +2.88**	**비용 따라 결정**	저비용이면 도입 · 고비용이면 재실험
0 위 · 실질 기준 아래	+0.02 ~ +0.18	보류	더 큰 변화 탐색
0 걸침 · 폭 넓음	−5.8 ~ +11.8	**판단 불가**	표본 재계산 후 새 실험
0 걸침 · 폭 좁음	−0.2 ~ +0.3	중단	다음 아이디어
전부 0 아래	−2.6 ~ −0.1	**폐기**	원인 탐색

함께 확인 · 가드레일 (앱 종료율 A 29.9% · B 30.4%) · 배정 비율 · 로그 누락 · 실질 기준은 사전 등록 대상

판단 · 5

검산 연습 : 이 보고서를 믿어도 되는가

받은 보고서 (AI 또는 교재)

A : 1,000명 중 50명 구매 (5.0%)

B : 1,000명 중 58명 구매 (5.8%)

«p = 0.04 · 우연일 확률 4% 미만

16% 상승 · **도입 결정**»

직접 계산

표준오차 1.01점 · z = 0.79

p = 0.43 · 95% CI −1.18 ~ +2.78점

판단 불가 · 표본 부족

5% → 6% 검출 필요 표본 집단당 약 8,158명

> p값 숫자도 해석 문장도 오류 · AI가 쓴 p값은 원자료로 재계산 필수

AI 함정 #9

p<0.05 단정

«유의미한 차이가 있습니다» 한 줄의 위험

함정 #9 · 증상

질문이 답을 결정

단문 요청

> 이 A/B 결과 유의미해?

흔한 응답

«p값이 0.022로 0.05보다 작으므로 통계적으로 유의미한 차이가 있습니다. B안을 적용하는 것이 좋습니다.»

효과 크기 · 신뢰구간 · 검정 횟수 · 가드레일 누락

명세 요청

> ab_result.csv의 A/B 결과 분석.
사전 등록 주 지표는 clicked 1개.
두 비율 차이 · 95% CI · n · z · 양측 p · 계산식을 표로.
left_app는 가드레일로 별도 표기.
«유의미» 대신 실제 차이와 범위로 서술.
중간 확인 여부를 나에게 질문.

함정 #9 · 원인과 진단

왜 생기고 어떻게 찾는가

원인

- 예·아니오형 질문 → 이분법 답변
- 보고 항목 미지정
- 실험 이력(검정 횟수·중간 확인)을 AI가 모름
- 계산 없이 문장만 생성한 수치 가능

진단 체크

- 효과 크기·신뢰구간·n·검정 횟수 존재?
- 사용한 코드와 중간 집계표 존재?
- 손계산 또는 다른 도구 결과와 일치?
- 중간 확인·지표 선택 이력 기재?

AI에 맡길 일 = 계산 · 사람이 맡을 일 = **실험 이력 제공과 결론의 범위 결정**

PART III · 50분

결과 해석
실습

모의 결과 검정 → 단정 재현 → 재요청 → 거짓 양성 체험



실습 · 1

이번 주 명세

[목표]
ab_result.csv의 A/B 결과를 보고 4종으로 정리하고 주장 가능 범위를 한 문단으로 작성

[제약]
- 주 지표 clicked 1개만 확증 분석 · 나머지 지표와 세부 집단은 탐색 결과로 표기
- «유의미합니다» «확실합니다» 표현 금지 · 실제 차이와 범위로 서술
- 분석 코드와 중간 집계표 함께 제출

[검증 조건]
- 배정 인원 · 클릭 수를 원본에서 다시 집계해 표기
- 차이 · 95% 신뢰구간 · z · 양측 p · 검정 횟수 표기
- 내 손계산 결과와 소수 둘째 자리까지 대조
- left_app를 가드레일로 별도 비교
- 마지막 줄 : 이 실험으로 주장할 수 없는 것 한 줄

[비목표]
- 그래프 꾸미기, 예측 모델, 인과 메커니즘 추측

실습 · 2

오늘의 실습 — 50분

#	활동	개념
1	ab_result.csv로 검정 요청 · 손계산 대조	기본 절차
2	«유의미한가?» 단문 요청 → 결과 저장	함정 #9
3	보고 4종 명세로 재요청 → 2번과 비교	보고 항목
4	ab_null.csv 분석 · 효과 0 실험 1,000회 시뮬레이션	거짓 양성
5	확장 : 일별 누적 p값 그래프 · 첫 유의 시점 찾기	조기 종료

합격 조건 · 검산값 일치 · 4번 유의 비율 약 5% 설명 · 단정 표현 0건 · **제출** · 명세 · 코드 · 대화 기록 · 보고 문단

실습 · 3

검산값 : AI 결과와 대조

파일	A	B	차이	95% CI	z	p (양측)
ab_result.csv	422 / 4,205	486 / 4,195	+1.55점	+0.22 ~ +2.88	2.29	**0.022**
ab_null.csv	433 / 4,177	380 / 4,223	−1.37점	−2.63 ~ −0.10	−2.12	**0.034**

> **ab_null.csv : A·B 모두 10%로 생성한 파일인데 «유의»**
> 실제 효과 0 · 거짓 양성 실물 · 효과 0 실험의 약 5%에서 발생

생성 규칙 · `data/make_ab.py` · 시드 고정 · 교육용 합성 데이터 · 5번 확장 : ab_null도 1~3일 차 p < 0.05 → 조기 종료였다면 잘못된 결론

실습 · 4

실무용 한 쪽 보고서

B 문구 클릭률 +1.55점 · 저비용 변경으로 도입 권고

실험 : 학식 쿠폰 화면 · 14일 · 재학생 8,400명 무작위 배정 (주 지표 사전 등록)

결과 : A 10.04% → B 11.59% · 95% CI +0.22 ~ +2.88점 · 검정 1회

부작용 : 앱 종료율 A 29.9% · B 30.4% · 차이 +0.48점 (95% CI −1.49 ~ +2.44) · 악화 미확인, 배제 불가

판단 : 효과 방향 양호 · 실질 기준 +2점 달성 여부 불확실 · 문구 변경 비용 거의 없음

다음 : 90% 배포 · 10% A 유지 2주 · 클릭 후 실제 쿠폰 사용률 추가 확인

한계 : 이번 학기 · 이 앱 사용자 범위 · 점심 외 시간대 일반화 불가

제목 쓰는 법

A/B 테스트 결과 보고

B 문구 +1.55점 · 저비용 도입 권고

AI 활용 범위

- 초안 문장 다듬기
- 표 형식 정리
- 수치·결론은 사람이 최종 확인

과제

공식 과제 : 결과 해석 연습

결과표	A	B	추가 정보	서술할 것
1	100 / 1,000	130 / 1,000	주 지표 · 종료 후 1회	유의 여부 · 구간 폭 · 결정
2	10 / 100	13 / 100	같은 비율 · 표본만 작음	1번과 달라지는 판단
3	100,000 / 1,000,000	101,000 / 1,000,000	구현 비용 큼	유의성과 실질 효과
4	지표 20개	1개만 p=0.03	사후 선택	다중 비교와 문구
5	3일 차 p=0.04	14일 차 p=0.21	3일 차에 보고 예정	중간 확인 문제

제출 · 표별 주장 가능 범위 3문장 이내 · AI 사용 기록 · 1~3번 계산은 코드와 손계산 대조

정리

10~11주 전체 절차

10주 · 실험 전

질문·가설
H_0 · H_1 선언

→

6요소 설계
대상·단위·처치
지표·기간·표본

→

사전 등록
주 지표 1개
중단 규칙

→

난수 배정
같은 사람
같은 버전

11주 · 실험 후

배정 점검
비율 · 사전 특성
로그 누락

→

검정·구간
기간 종료 후 1회
손계산 대조

→

보고 4종
효과 크기 · 신뢰구간
n · 검정 횟수

→

판단
도입·보류·재실험
실질 기준 비교

정리

한 장 요약

개념	핵심
표본 변동	효과 0에서도 차이 발생 · 표본이 클수록 우연의 폭 감소
p값	차이 없음을 가정할 때 지금 이상의 차이가 나올 확률
오해 3종	효과 없을 확률 아님 · 효과 크기 아님 · 재현 확률 아님
0.05	관행적 기준 · 사전 고정 · 0.049와 0.051의 증거 차이 미미
효과 크기 · 신뢰구간	유의 여부보다 크기와 범위 · 표본 100만 명의 +0.1점 사례
다중 비교	지표 20개 → 우연 유의 기대 1개 · 1개 이상 발생 64%
중간 확인	매일 확인 후 종료 → 거짓 양성 약 22% · 기간 사전 고정
보고 4종	효과 크기 · 신뢰구간 · n · 검정 횟수 · 확증/탐색 구분
AI 함정 #9	p<0.05 단정 → 보고 항목 지정 · 코드 요구 · 원자료 재계산

다음 주

데이터 기반 의사결정과 윤리

실험 결과를 쓰는 책임 · 지표의 왜곡 · 개인정보

AI 함정 #10 개인정보 그대로 출력